



**INGENIERÍA TÉCNICA EN INFORMÁTICA DE SISTEMAS**

**Curso Académico 2004 / 2005**

**Proyecto de Fin de Carrera**

**DETECCIÓN AUTOMÁTICA DEL COLOR DE LA  
PIEL EN IMÁGENES BIDIMENSIONALES BASADO  
EN EL ANÁLISIS DE REGIONES**

**Autor: Darío de Miguel Benito**

**Tutor: Juan José Pantrigo Fernández**

## **Agradecimientos**

Quiero dar las gracias de manera especial a Juan José Pantrigo Fernández por haberme facilitado sus conocimientos sobre Visión Artificial y por su gran ayuda y colaboración durante todo el proyecto. También quiero agradecer a Antonio Sanz Montemayor la ayuda prestada en momentos en los que Juanjo no estaba disponible.

Además de agradecer el apoyo prestado por estos profesores, no me puedo olvidar de mi novia, de mi familia y en especial de mi hermana, de mis compañeros y por supuesto amigos de clase e indudablemente de Jose y Oscar, compañeros del laboratorio del proyecto, además de grandes amigos.

## RESUMEN

El proyecto que se va a exponer se encuadra en el marco de trabajo de la Visión Artificial. Su objetivo es segmentar automáticamente las regiones correspondientes a la piel en imágenes a color, dando como resultado una imagen en la cual se etiquetan las regiones como “piel” y “no piel”.

Para llevar a cabo el proyecto ha sido necesario crear, en primer lugar, una base de datos de imágenes a color con la que entrenar, testear y validar el sistema creado para la detección de piel en imágenes estáticas a color. Esta base de datos consta de imágenes originales e imágenes tratadas manualmente para poder llevar a cabo las tareas mencionadas anteriormente.

Una vez coleccionada la base de datos de imágenes a color, se empezaron a implementar sencillos algoritmos de detección de piel. En paralelo a estos primeros algoritmos se fueron programando los algoritmos de entrenamiento del sistema. Posteriormente se desarrollaron algoritmos más sofisticados para la detección del color de la piel.

El núcleo de los algoritmos consiste en la comparación de los histogramas de cada región de la imagen con un histograma, obtenido en la etapa de entrenamiento. Esta comparación se realiza mediante la distancia o factor de Bhattacharya. Esta distancia es un número comprendido entre cero y uno que expresa la similitud entre dos histogramas.

La realización de los distintos algoritmos se ha basado en diferentes espacios de color: RGB, HSV y YCbCr, siendo el segundo con el que se han obtenido mejores resultados.

Para evaluar el rendimiento del sistema, se ha calculado el porcentaje de falsos positivos y falsos negativos para un conjunto de imágenes. Estos valores son una medida de la fiabilidad de los algoritmos.

Los resultados obtenidos son similares a los que se obtendrían al realizar la segmentación de la piel manualmente, puesto que el porcentaje de falsos positivos y falsos negativos es aceptable.

# Índice General

1. Introducción
  - 1.1. Conceptos generales
  - 1.2. Espacios de color
    - 1.2.1. Modelo RGB
    - 1.2.2. Modelo HSV
    - 1.2.3. Modelo YCbCr
    - 1.2.4. Otros modelos
  - 1.3. Histograma de una imagen
  - 1.4. Herramientas usadas
    - 1.4.1. Matlab 6.1
    - 1.4.2. Photoshop 7.0
2. Estado del arte: Modelado del color de la piel
  - 2.1. Definiciones explícitas de las reglas de las regiones de color
  - 2.2. Modelado no paramétrico de la distribución de la piel
    - 2.2.1. Lookup Table (LUT)
    - 2.2.2. Clasificación bayesiana
    - 2.2.3. Mapas auto-organizativos
    - 2.2.4. Resumen de métodos no paramétricos
  - 2.3. Modelado paramétrico de la distribución de la piel
    - 2.3.1. Modelo simple de Gauss
    - 2.3.2. Modelo de mezcla de gaussianas
    - 2.3.3. Agrupamiento con múltiples gaussianas
    - 2.3.4. Modelo de la frontera elíptica
    - 2.3.5. Resumen de métodos paramétricos
  - 2.4. Métodos de distribución de piel dinámicos
  - 2.5. Evaluación comparativa
3. Objetivo del proyecto
4. Descripción informática
  - 4.1. Trayectoria para la creación del proyecto
  - 4.2. Base de datos de las imágenes
  - 4.3. Algoritmos para el entrenamiento del sistema
  - 4.4. Algoritmos comunes al entrenamiento y al análisis del sistema

4.5. Algoritmos para el análisis del sistema

4.6. Falsos positivos y falsos negativos

5. Resultados experimentales

5.1. Test iniciales de verificación del entrenamiento

5.2. Resultados obtenidos en los espacios de color YCbCr y HSV

5.3. Análisis estadístico

6. Conclusiones y futuras líneas

Bibliografía

# Índice de Imágenes

Figura 1.1 : Representación de un píxel

Figura 1.2 : a) Imagen original, b) imagen corresponde a la estructura matricial de la imagen

Figura 1.3 : Imagen en blanco y negro

Figura 1.4 : Imagen en escala de grises

Figura 1.5 : Imagen en color

Figura 1.6 : Representación gráfica del modelo de color RGB

Figura 1.7 : Representación gráfica del modelo de color HSV

Figura 1.8: Representación de los colores en el cono del sistema HSV

Figura 1.9 : Representación gráfica del modelo de color HSL

Figura 1.10 : a) Imagen de Lena en escala de grises, b) histograma de la imagen

Figura 1.11: Interfaces de usuario: a) Matlab 6.1, b) Adobe Photoshop

Figura 4.1 : Modelo seguido en la elaboración del proyecto

Figura 4.2 : a) Imagen original de 109.jpg, b) imagen de la piel obtenida de 109.jpg

Figura 4.3 : a) Imagen original de 11.jpg, b) imagen de la piel obtenida de 11.jpg

Figura 4.4 : a) y b) Imágenes sin piel correspondientes a dos imágenes de la base de datos

Figura 4.5 : a) Imagen original de Beckham2.jpg, b) imagen con la piel en verde de Beckham2.jpg

Figura 4.6 : a), b) y c) Ejemplos de imágenes utilizadas para el entrenamiento del sistema

Figura 4.7 : Histogramas de entrenamiento del espacio de color RGB, respectivamente a), b) y c)

Figura 4.8 : Imagen en la que se ve una ventana que tiene que ser ajustada y otra que no

Figura 4.9 : Histograma de la componente V del espacio de color HSV

Figura 4.10 : a) Imagen de entrada del algoritmo MatrizBooleanExperto, b) y c) regiones en las que predomina el verde, por lo que en la matriz de salida habrá un uno, d) y e) regiones en las que predomina el verde, por lo que en la matriz de salida habrá un cero.

Figura 4.11 : a) Imagen original de CarlosSainz9.jpg, b) imagen obtenida al aplicar un algoritmo de detección de piel a la imagen anterior, donde se observan regiones de falsos positivos y falsos negativos.

Figura 4.12 : a) Imagen original de Camarera1.jpg, b) imagen tratada de Camarera1.jpg con la piel que reconocería una persona experta en segmentación en verde en verde

Figura 5.1 : a) Imagen original : Ciclistas.jpg, b) imagen de sólo la piel de la original y c) histograma de la componente R de la imagen de sólo piel

Figura 5.2 : a) Imagen original : Torero.jpg, b) imagen de sólo la piel de la original y c) histograma de la componente R de la imagen de sólo piel

Figura 5.3 : a) Imagen original : Jugador\_voley.jpg, b) imagen de sólo la piel de la original y c) histograma de la componente R de la imagen de sólo piel

Figura 5.4 : a) Imagen original : Hombre\_triste.jpg, b) imagen de sólo la piel de la original y c) histograma de la componente R de la imagen de sólo piel

Figura 5.5 : Histograma de entrenamiento de la componente R del espacio de color RGB

Figura 5.6 : Imagen i11.jpg

Figura 5.7: a) Imágenes originales. Imágenes tratadas con el algoritmo DetectorPielYCbCr con los siguientes umbrales para Cb y Cr: b) 0.8 y 0.0, c) 0.9 y 0.5, d) 0.0 y 0.8, e) 0.5 y 0.9, f) 0.8 y 0.8, respectivamente. Todas con un tamaño de región de 20\*20 píxeles

Figura 5.8: a) Imágenes originales, b) y c) imágenes tratadas con el algoritmo DetectorPielHSV1 con umbral S de 0.3 y 0.4, respectivamente, d) y e) imágenes tratadas con el algoritmo DetectorPielHSV2 con umbral S de 0.3 y 0.4 respectivamente. Ambos algoritmos con umbral H = 0.93 y tamaño de región de 20\*20 píxeles

Figura 5.9: a) Imágenes originales, b) y c) imágenes tratadas con el algoritmo DetectorPielHSV1 con umbral S de 0.3 y 0.4, respectivamente, d) y e) imágenes tratadas con el algoritmo DetectorPielHSV2 con umbral S de 0.3 y 0.4 respectivamente. Ambos algoritmos con umbral H = 0.93 y tamaño de región de 10\*10 píxeles

Figura 5.10 : a) Tatuaje2.jpg (Imagen original), b) Imagen tratada con un umbral de saturación (S) de 0.3, y c) Imagen obtenida con un umbral de saturación (S) de 0.4, además del umbral de 0.93 y de 0.4 para la H y la V respectivamente

Figura 5.11 : a) kruger.jpg (Imagen original), b) imagen tratada con un umbral de saturación de 0.3, y c) imagen obtenida con un umbral de saturación de 0.4

# Índice de Tablas

Tabla 2.1: Rendimiento de los métodos comparados

Tabla 5.1 : Distancia Bhattacharya entre los histogramas de la componente R y el histograma de entrenamiento de la misma componente

Tabla 5.2 : Distancia Bhattacharya entre sí de los histogramas de la componente R

Tabla 5.3 : Distancia Bhattacharya entre el histograma de cada componente de las veinte fotos y su histograma correspondiente de entrenamiento.

Tabla 5.4 : Distancia Bhattacharya entre los histogramas de la componente R (rojo) de veinte fotos de entrenamiento (solo piel)

Tabla 5.5 : Distancia Bhattacharya entre los histogramas de la componente G (verde) de veinte fotos de entrenamiento (solo piel)

Tabla 5.6 : Distancia Bhattacharya entre los histogramas de la componente B (azul) de veinte fotos de entrenamiento (solo piel)

Tabla 5.7 : Distancia entre el histograma de cada componente de las veinte fotos y su histograma correspondiente de entrenamiento.

Tabla 5.8 : Distancia Bhattacharya entre los histogramas de la componente H (tono) de veinte fotos de entrenamiento (solo piel)

Tabla 5.9 : Distancia Bhattacharya entre los histogramas de la componente S (saturación) de veinte fotos de entrenamiento (solo piel)

Tabla 5.10 : Distancia entre el histograma de cada componente de las veinte fotos y su histograma correspondiente de entrenamiento.

Tabla 5.11 : Distancia Bhattacharya entre los histogramas de la componente Cb de veinte fotos de entrenamiento (solo piel)

Tabla 5.12 : Distancia Bhattacharya entre los histogramas de la componente Cr de veinte fotos de entrenamiento (solo piel)

Tabla 5.13: Tabla de los falsos positivos y los falsos negativos del algoritmo DetectorPielHSV1.

Tabla 5.14: Tabla de los falsos positivos y los falsos negativos del algoritmo DetectorPielHSV2.



# Capítulo 1

## Introducción

### 1.1 Conceptos generales

Debido a que este proyecto se enmarca en el campo de la visión computacional, es necesario introducir algunos de los elementos básicos de la representación de imágenes [Esqueda 2002].

#### - Píxel

Es la abreviatura de las palabras inglesas “*picture element*” (figura 1.1). Es el menor de los elementos de una imagen al que se puede aplicar individualmente un color o una intensidad o que se puede diferenciar de los otros mediante un determinado procedimiento.



Figura 1.1 : Representación de un píxel

#### - Imagen digital

Una imagen digital se compone de una agrupación de píxeles, cada uno con un valor de intensidad o brillo asociado. Una imagen digital se representa mediante una matriz bidimensional, de forma que cada elemento de la matriz se corresponde con cada píxel en la imagen (ver figura 1.2).



a)

40	40	40	40	40	40	40	40	40	40
40	40	40	40	40	40	40	40	40	40
40	40	40	40	200	200	40	40	40	40
40	40	40	40	200	200	40	40	40	40
40	40	200	200	200	200	200	40	40	40
40	40	200	200	200	200	200	200	40	40
40	40	40	40	200	200	40	40	40	40
40	40	40	40	200	200	40	40	40	40
40	40	40	40	40	40	40	40	40	40
40	40	40	40	40	40	40	40	40	40

b)

Figura 1.2 : La imagen a) corresponde a la original. La imagen b) corresponde a la estructura matricial de la imagen

## - Clasificación de imágenes digitales

Dependiendo del rango de los valores que pueda tomar cada píxel podemos distinguir los siguientes tipos de imágenes:

Imágenes en blanco y negro: el rango está formado por los valores negro o blanco [0 1] únicamente. En la figura 1.3 se muestra una imagen de este tipo.




Figura 1.3 : Imagen en blanco y negro

Imágenes de intensidad: también conocidas como imágenes en escala de grises, existen hasta 256 niveles de grises, por lo que su rango se encuentra entre [0,255].




Figura 1.4 : Imagen en escala de grises

Imágenes en color: todo color se puede componer a partir de tres componentes básicas. El contenido de cada píxel de la imagen es una terna de valores, un valor por cada componente de color básico.

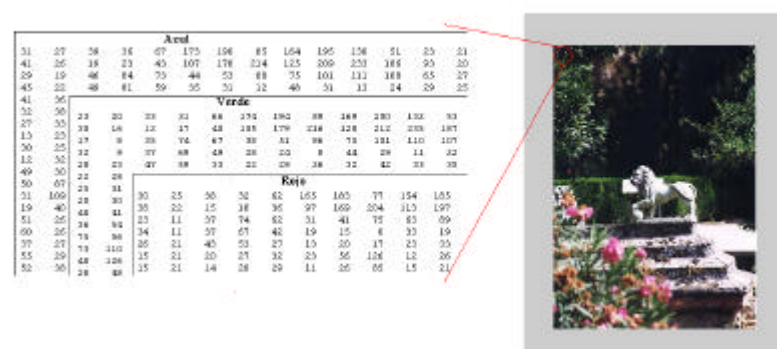


Figura 1.5 : Imagen en color

## 1.2 Espacios de color

### 1.2.1 Modelo RGB

Es uno de los modelos más utilizados por los sistemas informáticos para reproducir los colores en el monitor y en el escáner [Prádanos 2002]. Está basado en la síntesis aditiva de las intensidades de luz relativas al rojo, al verde y al azul para conseguir los distintos colores; incluyendo el negro y el blanco.

El nombre del modelo RGB viene de las iniciales, en inglés, de esos tres colores: Red, Green y Blue.




Figura 1.6 : Representación gráfica del modelo de color RGB

La representación gráfica del modelo RGB (ver figura 1.6) se realiza mediante un cubo unitario con los ejes R, G y B. El origen (0,0,0) representa el negro y las coordenadas (1,1,1) el blanco. Los vértices del cubo en cada eje R, G y B, de coordenadas (1,0,0), (0,1,0) y (0,0,1) representan los colores primarios rojo, verde y azul. Los restantes tres vértices (1,0,1), (0,1,1) y (1,1,0) al magenta, cian y amarillo respectivamente, colores secundarios y respectivamente complementarios del verde, rojo y azul. La diagonal del cubo representa la gama de grises desde el negro al blanco. En esta diagonal cada punto o color se caracteriza por tener la misma cantidad de cada color primario.

Las imágenes con modelo RGB contienen tres planos de imágenes independientes, uno para cada color primario. Cuando estas tres imágenes son proyectadas a un monitor RGB, la pantalla de fósforo produce una imagen de color compuesto [web1]. El procesamiento de imágenes en color, utilizando el modelo RGB, toma sentido cuando las imágenes se expresan naturalmente en términos de tres planos de color. Actualmente muchas cámaras a color utilizadas para adquirir imágenes digitales, utilizan el formato RGB.

Lo anterior convierte al modelo RGB en un modelo de gran importancia para el procesamiento de imágenes, a pesar de que no deriva en un proceso intuitivo para determinadas aplicaciones como por ejemplo la de comparar colores.

## 1.2.2 Modelo HSV

El modelo HSV fue creado en 1978 y está pensado en la definición del color que realizaría un artista. Las siglas H, S y V corresponden a Tono (hue), Saturación (saturation) y valor (value) respectivamente. También se denomina HSB, siendo B el brillo (brightness).

El sistema coordenado es cilíndrico, y el subconjunto de este espacio donde se define el color es una pirámide de base hexagonal [web4].




Figura 1.7 : Representación gráfica del modelo de color HSV

El área hexagonal corresponde a un valor de  $V = 1$ , conteniendo los colores más brillantes.




Figura 1.8: Representación de los colores en el cono del sistema HSV

El tono se mide como el ángulo alrededor del eje S. El rojo se sitúa a  $0^\circ$ , el verde a los  $120^\circ$  y el azul a los  $240^\circ$ . Los colores complementarios son aquellos que se encuentren a  $180^\circ$  del señalado. El rango de S se extiende desde 0 (coincidiendo con el eje de la pirámide) hasta 1, coincidiendo con el final del área hexagonal de la pirámide.

La pirámide tiene altura unidad. El vértice corresponde al negro con coordenadas  $S = 0$  y  $V = 0$ . El blanco corresponde a  $S = 0$  y  $V = 1$ . Los valores coincidentes con el eje de la pirámide son los grises. Cuando  $S = 0$  el valor de H no es importante y se dice que está indefinido. Cuando  $S > 0$ , el valor de H empieza a tener importancia. Por ejemplo, el rojo puro se sitúa a  $H = 0$ ,  $S = 1$  y  $V = 1$ . Si se añade blanco disminuye S, pero no cambia el valor de V. Las sombras se crean manteniendo  $S = 1$  y disminuyendo V.

La obtención de este espacio de color a partir del RGB es la siguiente:

$$\left. \begin{aligned} H &= \arccos \frac{\frac{1}{2}((R-G) + (R-B))}{\sqrt{((R-G)^2 + (R-B)(G-B))}} \\ S &= 1 - 3 \frac{\min(R, G, B)}{R + G + B} \\ V &= \frac{1}{3}(R + G + B) \end{aligned} \right| \quad (1)$$

donde R, G y B son los valores del canal rojo, verde y azul respectivamente.

### 1.2.3 Modelo YCbCr

YCbCr es una codificación no lineal del espacio de color RGB, usada comúnmente por los estudios de televisión europeos y en la compresión de imágenes. El color es representado por la luminancia (Y) y por dos valores diferentes de color (Cb y Cr) que son características colorimétricas del color.

La luminancia es la cantidad lineal de luz, directamente proporcional a la intensidad física, y ponderada por la sensibilidad de la percepción humana visible al espectro. La luminancia puede ser calculada como la suma ponderada de los componentes lineales del espacio de color RGB.

La obtención de este espacio de color a partir del RGB es la siguiente:

$$\left. \begin{aligned} Y &= 0.299R + 0.587G + 0.114B \\ C_r &= R - Y \\ C_b &= B - Y \end{aligned} \right| \quad (2)$$

siendo R, G y B son los valores del canal rojo, verde y azul respectivamente.

La sencillez de la transformación y la separación explícita de las componentes de luminancia y de crominancia del color, hacen a este espacio de color un método atractivo para la modelización del color de la piel.

### 1.2.4 Otros modelos

#### - Modelo HLS

Corresponde a un modelo de color definido por el tono (Hue), la luminosidad (Luminosity) y la saturación (Saturation). El espacio se define sobre una doble pirámide hexagonal. H es el ángulo alrededor del eje vertical, situándose el rojo a 0°. Los colores tienen el mismo orden que en el espacio HSV, estando su color complementario a 180° de él. La saturación se mide radialmente variando desde 0 a 1. La luminosidad es 0 para el negro (en el vértice inferior de la pirámide) y 1 para el blanco (en el vértice superior de la pirámide) [web4].




Figura 1.9 : Representación gráfica del modelo de color HSL

En este modelo los grises tienen todos el valor  $S = 0$  y los tonos más saturados se encuentran a  $S = 1$  y  $L = 0.5$ .

#### - Modelo CMY

Las siglas CMY corresponden a Cian, Magenta y amarillo (Yellow) que son los complementarios del rojo, verde y azul. Se denominan sustractivos ya que se utilizan como filtros para sustraer colores de la luz blanca. El sistema coordenado es el mismo que en el modelo RGB pero donde había negro ahora existe blanco y viceversa. Este sistema es el más usado en impresión [web4].

#### - Modelo TLS

Obtención de este espacio de color a partir del RGB [Vezhnevets et al. 2003]:

$$\begin{aligned} S &= [9/5(r'^2 + g'^2)]^{1/2} \\ T &= \begin{cases} \arctan(r'/g')/2\pi + 1/4, g' > 0 \\ \arctan(r'/g')/2\pi + 3/4, g' < 0 \\ 0, g' = 0 \end{cases} \\ L &= 0.299R + 0.587G + 0.114B \end{aligned} \quad (3)$$

siendo  $r' = r - 1/3$ ,  $g' = g - 1/3$ ; donde  $r$  y  $g$  son los valores normalizados de  $R$  y  $G$ :

$$r = R / (R+G+B) \text{ y } g = G / (R+G+B).$$


### 1.3 Histograma de una imagen

Un histograma de los niveles de cuantización de la imagen, o simplemente un histograma, es un diagrama de barras en el que sobre el eje de las abscisas se representan los diferentes valores que pueden tomar los píxeles de una imagen y en el eje de ordenadas el número de píxeles que se encuentran en una imagen para ese valor de cuantización [Vélez et al. 2003].

Se debe notar que los histogramas no representan ninguna información sobre la disposición espacial de los píxeles. Un histograma es una forma de representación de imágenes en la que se produce una pérdida de información.



a)



b)

Figura 1.10 : a) Imagen de Lena en escala de grises, y b) histograma de la imagen

Para evitar la dependencia entre el número de píxeles o el número de niveles de cuantización y el tamaño del histograma, se suele normalizar los ejes del histograma entre 0 y 1. Ésta es la razón por la que en los ejes no suelen aparecer las unidades.

Una manera de comparar histogramas es mediante la *distancia de Bhattacharya* [Srihari 2003]. Esta distancia es un factor de similitud entre dos vectores (en este caso, histogramas). Está comprendida entre 0 y 1, siendo 0 si los histogramas no se parecen nada y 1 si son el mismo.

## 1.4 Herramientas usadas

Las herramientas software utilizadas para la realización de este proyecto son Matlab 6.1 y Adobe Photoshop 7.0. Esta sección presenta una breve descripción de dichas herramientas

### 1.4.1 Matlab 6.1

Matlab 6.1 es un programa interactivo para computación numérica y visualización de datos. Es ampliamente usado por ingenieros de control en el análisis y diseño. Posee además, una extraordinaria versatilidad y capacidad para resolver problemas en matemática aplicada, física, química, ingeniería, finanzas y muchas otras aplicaciones. Permite resolver complicados problemas numéricos escribiendo programas sencillos.

El nombre de Matlab proviene de la contracción de los términos “**MAT**rix **LAB**oratory” y fue inicialmente concebido para proporcionar fácil acceso a las librerías más importantes en computación y cálculo matricial.

Se trata de un entorno de computación y desarrollo de aplicaciones totalmente integrado, orientado para llevar a cabo proyectos en donde se encuentren implicados elevados cálculos matemáticos y la visualización gráfica de los mismos. Integra herramientas para el análisis numérico, cálculo matricial, procesamiento de señal y visualización gráfica en un entorno completo donde los problemas y sus soluciones son expresados del mismo modo en que se escribirían tradicionalmente.

Su elemento básico de trabajo son las matrices. El programa permite realizar de un modo rápido la resolución numérica de problemas en un tiempo mucho menor que si se resolvieran con lenguajes de programación tradicionales como *Fortran*, *Basic* o *C*. Emplea las matrices porque con ellas se pueden describir diferentes objetos de una forma altamente flexible y matemáticamente eficiente.

En la actualidad goza de un alto nivel de aceptación en escuelas y centros universitarios, así como en departamentos de investigación y desarrollo de muchas compañías industriales nacionales e internacionales. En entornos universitarios, por ejemplo, se utiliza en los ámbitos docentes y de investigación. En el mundo industrial, está siendo utilizado como herramienta de investigación para la resolución de complejos problemas planteados en la realización y aplicación de modelos matemáticos en ingeniería.



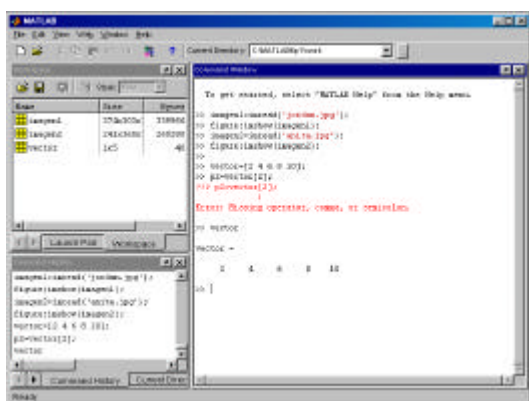
Además dispone también de un amplio abanico de programas de apoyo especializados, denominados *toolboxes*, que extienden significativamente el número de funciones incorporadas en el programa principal. Destacamos entre ellos el *toolbox* de proceso de imágenes, por el interés que tiene para el presente proyecto.

Para más información sobre la herramienta Matlab 6.1, se remite al lector a la Web [web5].

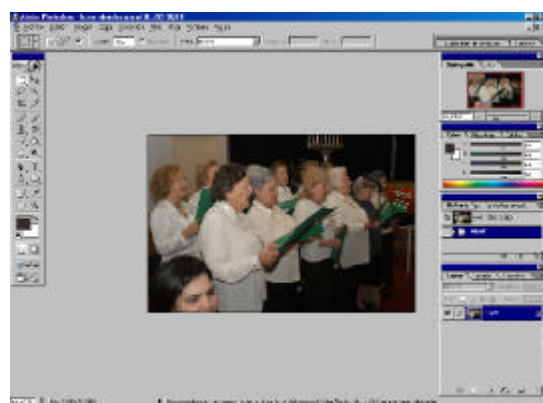
### 1.4.2 Adobe Photoshop

Adobe Photoshop es uno de los programas más utilizados por los profesionales de la imagen digital y diseñadores web para realizar sus creaciones. El programa ofrece cientos de herramientas para el tratamiento de imágenes, selección de zonas, herramientas de pintura, trazados, etc. Además el programa incorpora capas, cientos de filtros, efectos y controles de imagen como brillo, contraste, niveles, invertir, ecualizar, etc.

Para más información sobre el programa, se remite al lector a la Web [web2].



a)



b)

Figura 1.11: Interfaces de usuario: a) Matlab 6.1, b) Adobe Photoshop 7.0

## Capítulo 2

### Estado del arte: Modelado del color de la piel

El objetivo final del modelado del color de la piel es construir una regla de decisión que discrimine o diferencie entre los píxeles de una imagen que corresponden al color de la piel y aquéllos que no. Para ello se han utilizado diferentes métodos que se revisan en esta sección [Vezhnevets et al. 2003].

#### 2.1 Definiciones explícitas de regiones de color

Un método para construir un clasificador de piel consiste en definir específicamente los límites de la región correspondiente al color de la piel, a través de unas reglas numéricas. Este método es aplicable en diferentes espacios de color. En el trabajo [Peer et al. 2003] la regla para una imagen en RGB es:

$$\begin{aligned} &R > 95 \text{ and } G > 40 \text{ and } B > 20 \text{ and} \\ &\max\{R, G, B\} - \min\{R, G, B\} > 15 \text{ and} \\ &|R - G| > 15 \text{ and } R > G \text{ and } R > B \end{aligned} \quad (4)$$

La simplicidad de este método ha atraído y atrae el interés de muchas investigaciones [Peer et al. 2003], [Ahlberg 1999], [Fleck et al. 2002], [Jordao et al. 1999]. La ventaja de este método es la simplicidad de las reglas de detección de piel que permiten la clasificación rápida de píxeles. La principal desventaja de este método es la robustez, debido a la necesidad de encontrar espacios de color buenos y reglas de decisión empíricas adecuadas. Recientemente, ha sido propuesto un método que usa algoritmos de aprendizaje para encontrar espacios de color apropiados que lleven a cabo altas tasas de reconocimiento. Algunos autores [Gómez and Morales 2002] trabajan en el espacio rgb (RGB normalizado) y aplican un algoritmo para crear nuevos conjuntos de 3 atributos a partir de las componentes r, g, b y la constante 1/3 a través de operaciones algorítmicas básicas.

## 2.2 Modelado no paramétrico de la distribución de la piel

La idea clave de los métodos de modelado no paramétrico de la piel consiste en estimar la distribución del color de la piel por medio del entrenamiento de datos, sin derivar un modelo explícito. Generalmente, como resultado de la aplicación de estos métodos, se crea un mapa de probabilidad de piel (Skin Probability Map, SPM) [Brand and Marson 2000], [Gomez 2000], que consiste en la asignación de una probabilidad a cada punto de los distintos espacios de color.

### 2.2.1 Lookup Table (LUT)

Numerosos algoritmos de detección y seguimiento de caras [Chen et al. 1995], [Zarit et al. 1999], [Schumeyer and Barner 1998], [Sigal et al. 2000], [Soriano et al. 2000], [Birchfield 1998] utilizan un histograma basado en la segmentación de píxeles de piel. El espacio de color se cuantifica con un número determinado de intervalos, correspondiéndose cada uno con un rango particular o específico de color, compuesto por pares de valores (en representaciones en 2D), normalmente la crominancia sólo tiene un plano, o tríos (en 3D). Estos intervalos forman un histograma en 2D o 3D, que son referidos para mejorar la tabla LUT (Lookup Table). Cada intervalo almacena el número de veces que un color en particular aparece en las imágenes de entrenamiento. Después de la etapa de entrenamiento, los histogramas se normalizan, convirtiendo los valores de histograma en un modelo de probabilidad discreta:

$$P_{skin}(c) = \frac{skin[c]}{Norm} \quad (5)$$

donde el numerador, **skin(c)**, es el valor de intervalo del histograma, **c** es el vector de color y **Norm** es el coeficiente de normalización (sumatorio de todos los valores del histograma [Jones and Rehg 1999] o el máximo valor de los intervalos [Zarit et al. 1999]). Los valores de la tabla de búsqueda constituyen la posibilidad de que un color sea piel.

### 2.2.2 Clasificación bayesiana

El valor de la probabilidad **P<sub>skin</sub>(c)** obtenida en (5) es una probabilidad condicional **P(c|skin)**, que es la probabilidad de observar el color **c** sabiendo que el píxel es piel. Una medida más apropiada para la detección de piel podría ser **P(skin | c)**, que es la probabilidad de observar piel en un píxel de color **c**. Para obtener esta probabilidad se utiliza la regla de Bayes:

$$P(skin|c) = \frac{P(c|skin)P(skin)}{P(c|skin)P(skin) + P(c|\neg skin)P(\neg skin)} \quad (6)$$

$P(c | \text{skin})$  y  $P(c | \neg \text{skin})$  se obtienen directamente de los histogramas de color de piel y de los histogramas de no-piel (5). Las probabilidades  $P(\text{skin})$  y  $P(\neg \text{skin})$ , pueden ser estimadas por el número total de píxeles piel y no piel obtenidos en los entrenamientos [Jones and Rehg 1999], [Zarit et al. 1999], [Chai and Bouzerdoum 2000]. La desigualdad  $P(\text{skin}(c)) \geq \theta$ , donde  $\theta$  es un umbral, puede ser usado como una regla de detección de piel [Jones and Rehg 1999]. El valor de la probabilidad de que sea piel,  $P(\text{skin})$ , afecta solo a la elección del umbral  $\theta$ .

Se puede eludir la obtención explícita de (6), dado que solamente se necesita conocer la relación de  $P(\text{skin} | c)$  con  $P(\neg \text{skin} | c)$  y no sus valores exactos. Usando (6) la relación  $P(\text{skin} | c)$  y  $P(\neg \text{skin} | c)$  puede ser escrito como

$$\frac{P(\text{skin} | c)}{P(\neg \text{skin} | c)} = \frac{P(c | \text{skin})P(\text{skin})}{P(c | \neg \text{skin})P(\neg \text{skin})} \quad (7)$$

Comparando la formula (4) con el umbral de las reglas de detección de piel y no piel, se puede describir como:

$$\begin{aligned} \frac{P(c | \text{skin})}{P(c | \neg \text{skin})} &> \Theta \\ \Theta &= K \times \frac{1 - P(\text{skin})}{P(\text{skin})} \end{aligned} \quad (8)$$

### 2.2.3 Mapas auto-organizativos

Los mapas auto-organizativos (SOM) fueron propuestos por Kohonen en la década de los 80. En la actualidad constituyen uno de los tipos de redes de neuronas artificiales más populares. En [Brown et al. 2001] fue propuesta una base de detección de piel mediante SOM. Dos SOM, una para solo-piel y otra de piel-no piel, fueron entrenadas con un conjunto de 500 imágenes etiquetadas manualmente. El rendimiento de los detectores fue probado utilizando un conjunto de imágenes de diferentes autores y con la popular base de datos de piel de Compaq. Fueron testados con el detector SOM numerosos espacios de color (RGB normalizado, tono - saturación, tono - saturación cartesiano y el plano de crominancia de TSL). Los resultados mostraron que los detectores de piel SOM no presentan cambios bruscos de rendimiento cuando utilizan diferentes espacios de color.

A pesar de que el rendimiento de los SOM es inferior al los métodos basado en histograma o los mixtos, el método sigue teniendo interés debido a que necesita menos recursos que éstos.

## 2.2.4 Resumen de métodos no paramétricos

Las dos claras ventajas de los métodos no paramétricos consisten en que:

- Son rápidos para entrenar y usar
- Son teóricamente independientes de la forma de la distribución de piel.

Las múltiples desventajas están relacionadas con el espacio de almacenamiento requerido e inhabilitado para interpolar o generalizar el entrenamiento de datos. Para reducir la cantidad de memoria necesaria y tener en cuenta la escasez de datos de entrenamiento, se utilizan espacios de color gruesos (128x128x128, 64x64x64, 32x32x32, etc). La evaluación de diferentes ejemplos de RGB en [Jones and Rehg 1999] demostraron que 32x32x32 es el más adecuado.

## 2.3 Modelado paramétrico de la distribución de la piel

Los problemas de almacenamiento y dependencia de la representación que muestran los modelos no paramétricos estimula la necesidad de desarrollar modelos de piel más compactos para ciertas aplicaciones, que permitan generalizar e interpolar los datos de entrenamiento. Este tipo de modelos obedece a la descripción de los modelos paramétricos de la distribución de la piel.

### 2.3.1 Modelo simple de Gauss

La distribución del color de piel puede ser modelada por una función de densidad de probabilidad elíptica de Gauss (PDF) definida como

$$p(\mathbf{c}|\mathbf{skin}) = \frac{1}{2\pi|\Sigma_s|^{1/2}} \cdot e^{-\frac{1}{2}(\mathbf{c}-\mu_s)^T \Sigma_s^{-1}(\mathbf{c}-\mu_s)} \quad (9)$$

siendo  $\mathbf{c}$  un vector de color, y  $\mu_s$  y  $\Sigma_s$  son los parámetros de la distribución (vector de medias y matriz de covarianzas, respectivamente). Los parámetros del modelo son estimados en la etapa de entrenamiento por:

$$\mu_s = \frac{1}{n} \sum_{j=1}^n \mathbf{c}_j; \quad \Sigma_s = \frac{1}{n-1} \sum_{j=1}^n (\mathbf{c}_j - \mu_s)(\mathbf{c}_j - \mu_s)^T \quad (10)$$

donde  $n$  es el número total de ejemplos de color de piel  $\mathbf{c}_j$ . La probabilidad  $P(\mathbf{c}|\mathbf{skin})$  puede ser usada directamente como la probabilidad de que el color  $\mathbf{c}$  sea piel [Menser and Wien 2000], o también se puede utilizar la distancia de Mahalanobis entre  $\mathbf{c}$  y  $\mu_s$  dada la matriz de covarianza  $\Sigma_s$  [Terrillon et al. 2000].

$$\lambda_s(c) = (c - \mu_s)^T \Sigma_s^{-1} (c - \mu_s) \quad (11)$$

El método de modelización de Gauss fue también empleado en [Hsu et al. 2002], [Ahlberg 1999], [Yang and Ahuja 1998], [Saber and Tekalp 1998].

### 2.3.2 Modelo de mezcla de gaussianas

Un modelo más sofisticado, capaz de describir formas complejas de distribución es el modelo de mezcla de gaussianas. Este modelo es la generalización del modelo de gaussiana simple. En este caso la función de probabilidad es:

$$p(c|skin) = \sum_{i=1}^k \pi_i \cdot p_i(c|skin) \quad (12)$$

Aquí  $k$  es el número de componentes de la mezcla.  $\pi_i$  son los parámetros de la mezcla, tal que  $\sum_{i=1}^k \pi_i = 1$ , y  $P(c|skin)$  son las funciones de densidad de probabilidad de Gauss. El modelo de entrenamiento utiliza el algoritmo EM (Expectation-Maximization), que supone conocido el número de componentes  $k$ . Los detalles del entrenamiento con el modelo de mezcla gaussiana con EM pueden ser encontrados en [Yang and Ahuja 1999] y [Terrillon et al. 2000].

El número de componentes  $k$  es importante. El modelo necesita, por un lado, explicar razonablemente bien el comportamiento de los datos y, por otro lado, evitar datos sobre ajustados. El número de componentes usadas para diferentes búsquedas va desde 2 [Yang and Ahuja 1999] hasta 16 [Jones and Rehg 1999]. Una prueba para  $k = 2$  se puede encontrar en [Yang and Ahuja 1999] y para  $k = 8$  en [Terrillon et al. 2000]. También se usan modelos de mezcla de Gauss en [McKenna et al. 1998] y [Oliver et al. 1997].

### 2.3.3 Agrupamiento con múltiples gaussianas

En [Phung et al. 2002] se describe una solución al problema de la clasificación basado en el agrupamiento de color de piel con tres gaussianas 3D. El píxel es clasificado como piel, si la distancia de Mahalanobis desde el vector de color  $c$  al patrón del modelo del grupo es inferior a un umbral predefinido.

### 2.3.4 Modelo de la frontera elíptica

Examinando distribuciones de piel y no-piel en varios espacios de colores, Lee y Yoo [Lee and Yoo 2002] encontraron que el grupo del color de la piel es aproximadamente elíptico y, por lo tanto, no se modela suficientemente bien a través de un modelo de gaussianas simples. El uso

del modelo simétrico de Gauss produce el índice más alto de falsos positivos, debido a la asimetría de los agrupamientos del color de la piel con respecto a su punto de mayor densidad.

Los autores proponen una alternativa llamada “*Modelo de la Frontera Elíptica*” el cual es igualmente rápido y simple en entrenamiento y evaluación como el modelo simple de Gauss y obtiene un mejor resultado en detecciones en el la base de datos Compaq [Jones and Rehg 1999], comparando la sencilla Gaussiana y mezcla de Gauss. El modelo elíptico es definido como:

$$\Phi(c) = (c - \phi)^T \Lambda^{-1} (c - \phi) \quad (13)$$

El procedimiento del modelo de entrenamiento consta de dos pasos:

- 1) Se elimina alrededor del 5% de los ejemplos del color del entrenamiento con bajas frecuencias para reducir el ruido y los datos despreciables.
- 2) Los parámetros del modelo  $\phi$  y  $\Lambda$  son estimados utilizando

$$\begin{aligned} \phi &= \frac{1}{n} \sum_{i=1}^n c_i; & \Lambda &= \frac{1}{N} \sum_{i=1}^n f_i \cdot (c_i - \mu)(c_i - \mu)^T; \\ \mu &= \frac{1}{N} \sum_{i=1}^n f_i c_i; & N &= \sum_{i=1}^n f_i; \end{aligned} \quad (14)$$

donde  $n$  es el numero total de vectores de color de entrenamiento característicos  $c_i$  del conjunto de píxeles de piel de entrenamiento (que no es el numero total de muestras). Y  $f_i$  es el número de muestras de piel del vector de color  $c_i$ . Los píxeles con color  $c$  son clasificados como piel cuando  $\Phi(c) < \epsilon$ , donde  $\epsilon$  es un valor umbral.

### 2.3.5 Resumen de métodos paramétricos

Todos los métodos paramétricos descritos (excepto los de la sección 2.3.3) operan en el plano del espacio de color de la crominancia, ignorando la información que aporta la luminancia.

Cuando se usa un modelo explícito de distribución surge la cuestión de crear un modelo de validación. Sólo algunos autores han justificado teóricamente los modelos que han usado. [Yang et al. 1998] ha mostrado que la distribución del color de piel de una persona bajo condiciones de luz fija y un espacio RGB normalizado sigue una distribución gaussiana. [Yang and Ahuja 1999] ha justificado la hipótesis de normalidad en los datos de piel en el espacio CIELuv y valida el modelo de mezcla de Gauss de dos componentes por la realización de test estáticos.

## **2.4 Métodos de distribución de piel dinámicos**

El conjunto de métodos de modelización de piel especializados en la detección de caras en secuencias de imágenes ha constituido una familia con personalidad propia. Esta tarea hace diferente la detección del análisis estático de la imagen en algunos aspectos. En principio el modelo de piel puede ser menos generalizado, más específico. Por ejemplo, puede depender de una persona concreta, de una cámara o de unas condiciones de iluminación. En segundo lugar, la inicialización en la escena es posible cuando la región de la cara es discriminada del fondo a través de clasificadores o bien manualmente. Por lo tanto, no existe la necesidad de obtener modelos generales, y es posible conseguir altas tasas de reconocimiento con modelos específicos. Por otro lado, la distribución del color de piel puede variar con el tiempo debido a los cambios en iluminación o al balance de blancos de la cámara. De este modo, surge la necesidad de que el modelo se auto-actualice para contemplar los cambios en las condiciones de iluminación. El tiempo de clasificación es extremadamente importante en este tipo de aplicaciones, ya que suele ser requisito trabajar en tiempo real, consumiendo pocos recursos del ordenador.

Resumiendo, las propiedades más importantes del modelo de color de piel para la detección o búsqueda de caras son:

- 1.- debe ser rápido tanto en el entrenamiento como en la clasificación
- 2.- debe auto actualizarse para cambiar las condiciones.

## **2.5 Evaluación comparativa**

Para evaluar de los diferentes métodos de modelado del color de la piel es necesario estudiar el rendimiento bajo las mismas condiciones. La base de datos de imágenes más famosa es la base de datos de Compaq [Jones and Rehg 1999]. En la siguiente tabla se muestran los mejores resultados de los diferentes métodos propuestos por los autores para esta base de datos. En la tabla podemos observar la tasa de verdaderos positivos (True Positives) y los falsos positivos (False Positives), TP y FP respectivamente, para los diferentes métodos. Estos métodos emplean diferentes estrategias y usan subconjuntos de imágenes de la base de datos en el entrenamiento y en el testeo. La Tabla 1 da una visión del rendimiento de los métodos.

El mejor rendimiento (pocos falsos positivos para una tasa de detección dada) ha sido alcanzada por Bayes SPM y por el Maximun Entropy Model [Jedynak et al.2002]. Las técnicas paramétricas de modelización, Gaussianas, mezcla de Gaussianas, modelo límite elíptico, están por detrás de las detecciones basadas en la SOM. El alto rendimiento el modelo mixto de Gauss



usado en [Jones and Rehg 1999] es debido a que modeliza ambas PDFs, es decir  $p(\text{RGB} | \text{skin})$  y  $p(\text{RGB} | \neg\text{skin})$ , en contraste con otros modelos paramétricos de piel.

Tabla 2.1: Rendimiento de los métodos comparados

Method	TP	FP
Bayes SPM in RGB [Jones and Reg. 1999]	80 % 90 %	8.5 % 14.2 %
Bayes SPM in RGB [Brand and Mason 2000]	93.4 %	19.8 %
Maximum Entropy Model in RGB [Jedynak et al. 2002]	80 %	8.0 %
Gaussian Mixture models in RGB [Jones and Reg. 1999]	80 % 90 %	9.5 % 15.5 %
SOM in TS [Brown et al. 2001]	78 %	32.0 %
Elliptical boundary model in CIE-xy [Lee and Yoo 2002]	90 %	20.9 %
Single Gaussian in CbCr [Lee and Yoo 2002]	90 %	33.3 %
Gaussian Mixture in IQ [Lee and Yoo 2002]	90 %	30.0 %
Thresholding of I axis in YIQ [Brand and Mason 2000]	94.7 %	30.2 %

La principal ventaja de los métodos que definen explícitamente el límite del conjunto de la piel es la simplicidad de sus reglas (apartado 2.1). Sin embargo el problema con estos métodos es la necesidad de encontrar buenos espacios de color y adecuadas reglas de decisión empírica.

Los métodos no paramétricos (apartado 2.2) son rápidos en el entrenamiento y en la clasificación, independientemente de la forma de la distribución y por lo tanto de la selección del espacio de color. Pero ello requiere mucho espacio de almacenamiento y un entrenamiento con un conjunto representativo de los datos.

Los métodos paramétricos (apartado 2.3) pueden también ser rápidos. Permiten interpolar y generalizar el entrenamiento de datos incompletos. El modelo es expresado por un pequeño número de parámetros y, por tanto, necesita muy poco espacio de almacenamiento. Su rendimiento depende en gran medida de la forma de la distribución de la piel. Muchos métodos paramétricos de modelización de la piel ignoran el color no-piel estático. Esto junto con la dependencia de la forma del grupo de piel, da lugar a altas tasas de falsos positivos, en comparación con los métodos no paramétricos.

## Capítulo 3

### Objetivos

El objetivo de este proyecto es *segmentar automáticamente los píxeles correspondientes a la piel en imágenes a color a través de un enfoque basado en la comparación de histogramas de regiones de la imagen*. Como resultado de la aplicación del detector sobre una imagen se espera obtener una imagen en la que sólo se visualicen los píxeles de las regiones correspondientes al color de la piel, dejando los demás en blanco. Este objetivo se articula en los siguientes objetivos operativos:

- Coleccionar un número suficiente de imágenes a color.
- Aprender a utilizar el entorno de programación Matlab.
- Crear los algoritmos de entrenamiento del sistema
- Entrenar el sistema.
- Desarrollar los algoritmos de detección de piel.
- Comprobar eficacia de los algoritmos de detección de piel.
- Observando los resultados, mejorar los algoritmos de detección de piel.

## Capítulo 4

### Descripción Informática

Una vez descritos los objetivos que se desean conseguir con la realización del proyecto, en este capítulo se van a tratar los distintos aspectos que componen la especificación del mismo.

#### 4.1 Trayectoria para la creación del proyecto

Los pasos seguidos para la realización del proyecto (ver figura 4.1) han sido los siguientes:

##### 1.- Revisión bibliográfica

El primer paso fue recopilar la información necesaria para la realización del proyecto y familiarizarse con el área de conocimiento de la visión artificial. Esta información fue obtenida gracias a artículos facilitados por el tutor del proyecto, por otros buscados en Internet y mediante libros relacionados con la materia.

##### 2.- Colección de imágenes a color para la base de datos

Se ha recopilado una amplia colección de imágenes (procedentes de diferentes fuentes) para poder llevar a cabo el proyecto. Para más información sobre la base de datos de imágenes a color se remite al apartado 4.2.

##### 3.- Realización de sencillos algoritmos

Como toma de contacto con el entorno, se crearon sencillos algoritmos para observar los primeros resultados del filtrado del color de la piel, basados en sistemas de reglas simples.

##### 4.- Creación de los algoritmos de entrenamiento del sistema

Posteriormente se elaboraron los algoritmos necesarios para entrenar el sistema. Estos algoritmos consisten en el cálculo de los histogramas de las distintas imágenes de entrenamiento. Estos histogramas se suman por canales de color y se normalizan para obtener los histogramas de entrenamiento de cada componente.

##### 5.- Creación de los algoritmos de detección de piel

En esta etapa del proyecto se construyen los algoritmos centrales. Estos algoritmos se basan, en su mayoría, en la distancia de Bhattacharya. Con estos algoritmos y gracias al entrenamiento

del sistema, se obtiene una discriminación entre las regiones consideradas como piel y regiones que no se consideran como tales. Las regiones que se consideran piel aparecen tal como son en la imagen original, y el resto aparecen de color blanco.

## 6.- Validación del sistema

Para validar el sistema se comprueba su eficacia con un conjunto de imágenes de test, diferente al utilizado en el entrenamiento. También se realiza un estudio probabilístico de los falsos positivos y los falsos negativos de un conjunto suficiente de imágenes.

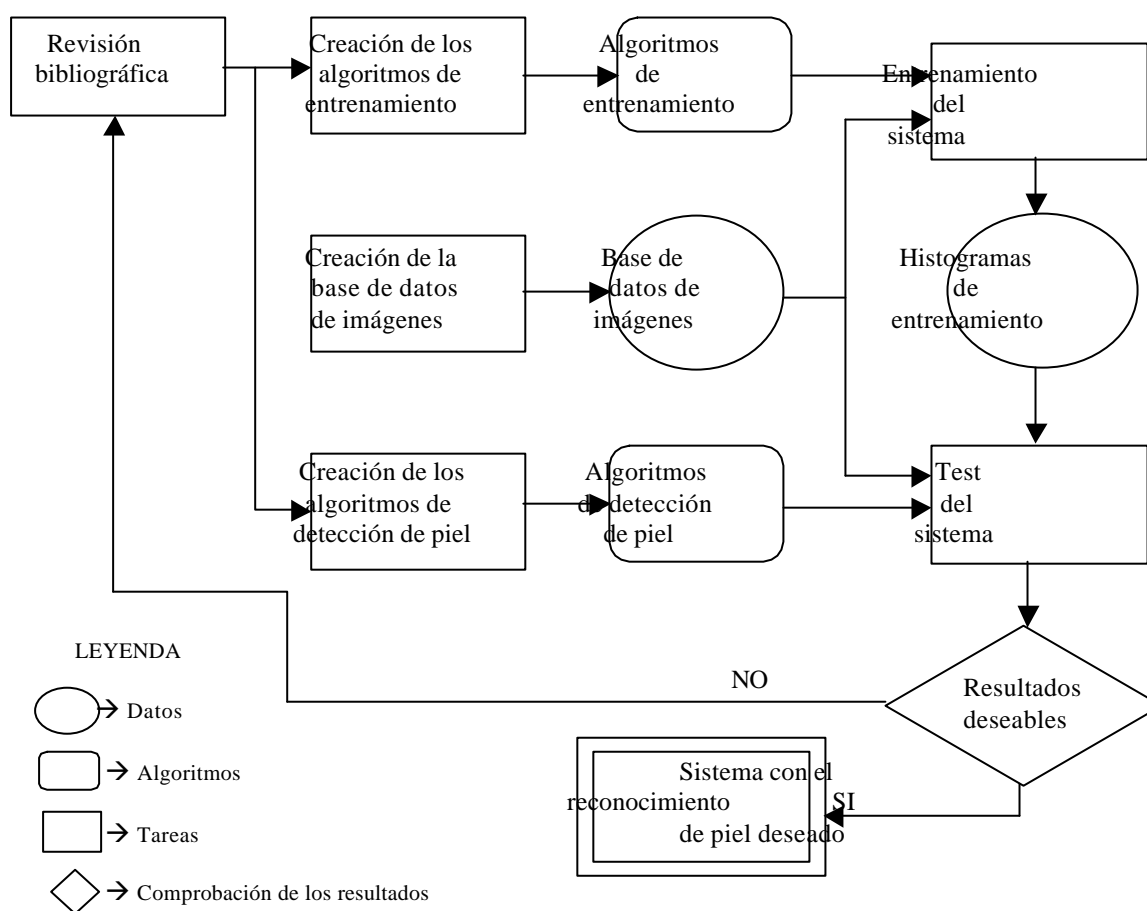


Figura 4.1 : Modelo seguido en la elaboración del proyecto

## 4.2 Base de datos de imágenes

Para la realización del proyecto ha sido necesario coleccionar una gran cantidad de imágenes para el entrenamiento del sistema o aprendizaje y para su validación. Esta base de datos se intentó conseguir contactando con investigadores de este ámbito, pero esto no fue posible y se decidió crear una base de datos propia con imágenes de diferentes fuentes. Estas imágenes están almacenadas en varios formatos (jpg, bmp, gif, tif ...). El número de imágenes es elevado, para que pueda ser utilizada en futuros trabajos. Consta de 2.737 imágenes, de las cuales:

- 2.314 imágenes son originales de distintos tamaños (ver figuras 4.2 a), 4.3 a) y 4.5 a))
- 164 imágenes en las que sólo aparece piel en fondo blanco (necesarias para entrenar el sistema) (ver figuras 4.2 b), 4.3 b) y 4.5 b))
- 220 imágenes en las que no aparece piel (ver figura 4.4)
- 39 imágenes en las cuales aparece el color de la piel de un tono verde de fácil identificación automática (necesarias para el cálculo de los falsos positivos y negativos) (ver figura 4.5 b)).

A continuación se muestran ejemplos de las imágenes que forman la base de datos creada:




Figura 4.2 : a) Imagen original 109.jpg, b) imagen de la piel obtenida de 109.jpg




Figura 4.3 : a) Imagen original 11.jpg, b) imagen de la piel obtenida de 11.jpg



Figura 4.4 : a) y b) Imágenes sin piel correspondientes a dos imágenes de la base de datos




Figura 4.5 : a) imagen original de Beckham2.jpg, b) imagen con la piel en verde de Beckham2.jpg

### 4.3 Algoritmos para el entrenamiento del sistema

Para que el sistema detecte piel en imágenes, es necesario entrenarlo. El entrenamiento del sistema consiste en el cálculo de un histograma a partir de imágenes de piel segmentadas manualmente (ver figura 4.6). Se ha creado un histograma para cada componente de los espacios de color tratados. Es decir, tres histogramas para el espacio de color RGB, para el rojo, verde y azul (ver figura 4.7), tres para las componentes HSV y otras tres para el YCbCr. Estos histogramas de entrenamiento han sido calculados utilizando imágenes de piel sobre fondo blanco.




Figura 4.6 : a), b) y c) Ejemplos de imágenes utilizadas para el entrenamiento del sistema

Estos algoritmos recorren la imagen píxel a píxel descartando los que son blancos (no-piel) y contabilizando los demás, obteniendo un vector de frecuencias de aparición de intervalos de color. Este vector es el histograma de entrenamiento para esa imagen. Repitiendo este proceso sobre el conjunto de imágenes de entrenamiento obtenemos el histograma de entrenamiento para cada componente de los espacios de color. A continuación se muestra en pseudocódigo dicho algoritmo:

```

MIENTRAS haya imágenes en la carpeta HACER:
    Leer la imagen;
    DESDE x := 1 HASTA el número de filas HACER:
        DESDE y := 1 HASTA el número de columnas HACER:
            SI imagen(x,y) <> blanco ENTONCES:
                p := 1;
                MIENTRAS imagen(x,y) <= vector[p] HACER:
                    p := p + 1;
                FIN MIENTRAS;
                vector[p] := vector[p] + 1;
            FIN SI;
        FIN DESDE;
    FIN DESDE;
FIN MIENTRAS;

DESDE i := 1 HASTA n_bins HACER:
    suma := suma + vector[i];
FIN DESDE;
DESDE i := 1 HASTA n_bins HACER:
    sector[i] := vector[i] / suma;
FIN DESDE;

Salida := vector;
    
```

Es necesario adaptar este algoritmo para cada espacio de color, puesto que el color blanco tiene un valor distinto en cada uno. En concreto, el blanco en RGB es (1,1,1), en HSV es (0,0,1) y en YCbCr es (0.9216, 0.5020, 0.5020).




Figura 4.7 : Histogramas de entrenamiento de las componentes del espacio de color RGB, respectivamente a), b) y c)

También se ha creado un algoritmo para calcular la distancia de Bhattacharya. Este factor o distancia permite comparar dos histogramas. A continuación se muestra el pseudocódigo de la función Bhattacharya:

```

valorAuxiliar := 0;
total := 0;
DESDE i := 1 HASTA n_bins HACER:
    valorAuxiliar = sqrt( vector1[i] ) * sqrt( vector2[i] );
    total = total + valorAuxiliar;
FIN DESDE;
salida = total;
    
```

donde `vector1` y `vector2` son los histogramas que se necesita comparar; y `n_bin` el número de elementos de los mismos.

El resultado del proceso es el factor de comparación entre los dos histogramas. Este factor es cercano a uno si los histogramas se parecen, es uno si son iguales, y cercano a cero si no tienen parecido alguno.

## 4.4 Algoritmos comunes al entrenamiento y al análisis

Además de los algoritmos mencionados en el apartado anterior, algoritmos de entrenamiento, se han necesitado algunos auxiliares que también se han utilizado en el test y en la validación del sistema. Los más significativos son los siguientes:

- HistogramaCapa:
  - Propósito: calcular el histograma de una imagen en escala de grises.
  - Entrada: imagen, número de intervalos del histograma de salida.
  - Salida: histograma de la imagen.
  - Descripción: halla el histograma de una imagen en escala de grises. Esta imagen en escala de grises puede ser una capa o componente de un espacio de color
- HistogramaPielRGB:
  - Propósito: calcular el histograma de un canal de una imagen de solo piel.
  - Entrada: imagen, canal del espacio de color, número de intervalos del histograma de salida.
  - Salida: histograma del canal de la imagen.
  - Descripción: es usado para imágenes de sólo piel con fondo blanco. Halla el histograma de un canal del espacio de color sin contabilizar los píxeles blancos. Es decir, halla el histograma como si sólo hubiera piel.

Este procedimiento es similar para los espacios de color HSV e YCbCr. Cambia la forma de comprobar si el píxel es piel. En RGB compara que sea distinto de (1,1,1) que es el blanco en RGB y para HSV e YCbCr el blanco es (0,0,1) y (0.9216, 0.5020, 0.5020) respectivamente.

Además de estos procedimientos, se han creado unos programas que facilitan el desarrollo y una mejor programación del proyecto:



- **LanzarHist\_DistBhatta:**
  - Propósito: calcular los histogramas de los tres canales de un espacio de color para veinte imágenes. También calcula su distancia Bhattacharya respecto a los respectivos histogramas de entrenamiento
  - Entrada: los tres histogramas de entrenamiento del espacio de color, el archivo donde están las imágenes de entrenamiento y los ficheros donde se guardarán los resultados.
  - Salida: copia en ficheros '.txt' los histogramas y las distancias Bhattacharya calculados.
  - Descripción: halla los histogramas de las tres componentes de cada imagen y las compara mediante la distancia de Bhattacharya con sus correspondientes histogramas de entrenamiento. Los histogramas hallados y las distancias de Bhattacharya se guardan en ficheros '.txt'.

Este programa se adapta a todos los espacios de color (RGB, HSV, YCbCr) porque tanto los histogramas de entrenamiento como los ficheros donde se guardarán los resultados son entradas del programa.

- **LanzarBhattaEntreHist:**
  - Propósito: calcular la distancia Bhattacharya entre veinte histogramas de un canal de un espacio de color.
  - Entrada: fichero con los histogramas de un canal de un espacio de color creado con el programa LanzarHist\_DistBhatta y el fichero donde se guardarán los resultados.
  - Salida: copia en un fichero '.txt' las distancias Bhattacharya calculadas.
  - Descripción: dado un fichero con los histogramas en una componente de las veinte imágenes tratadas en el procedimiento LanzarHist\_DistBhatta, devuelve un fichero '.txt' con la distancia Bhattacharya entre todos los histogramas.

## **4.5 Algoritmos para el análisis del sistema**

En esta fase del proyecto ya se ha entrenado el sistema y el objetivo es comprobar su comportamiento. Para ello se crean distintos algoritmos que van recorriendo la imagen en regiones decidiendo si es piel o no. Si la región es piel, en la imagen de salida aparece esa región en el mismo lugar que en la imagen de entrada al sistema. Si la región analizada no es piel, se sustituirá por una región blanca en la imagen de salida.

A continuación se exponen los algoritmos necesarios para el análisis de la aplicación. Posteriormente se comentan sus mejoras en cada caso y los motivos de la elección de los umbrales.

- **HistogramaRegión:**
  - Propósito: calcular el histograma de una región de una imagen en escala de grises.
  - Entrada: imagen, esquina superior izquierda de la región, tamaño de la región, intervalos del histograma de salida.
  - Salida: histograma de la región.
  - Descripción: halla el histograma de una región dada de una imagen en niveles de gris. La región está definida por el vértice superior izquierdo. Esta imagen en niveles de gris suele ser un canal de un espacio de color.

NOTA: si la ventana excede las dimensiones de la imagen, se ajusta su tamaño para evitar errores de desbordamiento.




Figura 4.8 : Imagen en la que se ve una ventana que tiene que ser ajustada y otra que no

- **ValorMedio:**
  - Propósito: calcular el valor medio de una región de una imagen en niveles de gris.
  - Entrada: imagen, canal del espacio de color, esquina superior izquierda de la región, tamaño de la región.
  - Salida: valor medio de la región.

- Descripción: halla el valor medio de una región de una imagen en niveles de gris. Esta imagen de grises suele ser un canal de un espacio de color.
- DetectorPielYCbCr:
  - Propósito: segmentar automáticamente las regiones de piel de una imagen.
  - Entrada: imagen, tamaño de las regiones, histograma de entrenamiento de Cb, histograma de entrenamiento de Cr, umbral de Cb, umbral de Cr.
  - Salida: imagen segmentada, en la que sólo se reflejan las regiones consideradas como piel.
  - Descripción: este procedimiento trata las imágenes en el espacio YCbCr, aunque la entrada sea en RGB. Recorre la imagen en regiones hallando los histogramas de sus componentes. Estos histogramas son comparados con el de entrenamiento mediante el algoritmo de Bhattacharya. Si dicha distancia es mayor que un umbral dado, se considera la región piel. Esta comparativa se puede hacer con la componente Cb, con la Cr y con las dos. No se utiliza la componente Y porque es la que nos da información de la luminosidad de la imagen.
- DetectorPielHSV1:
  - Propósito: segmentar automáticamente las regiones de piel de una imagen.
  - Entrada: imagen, tamaño de las regiones, histograma de entrenamiento de H, histograma de entrenamiento de S, umbral de H, umbral de S.
  - Salida: imagen segmentada, en la que sólo se conservan las regiones consideradas como piel y una matriz booleana.
  - Descripción: examina regiones de la imagen catalogándolas como piel y no piel. Si es piel la conserva en la imagen de salida y si no lo es, la sustituye por una región blanca. Para que la región sea clasificada como piel, la distancia de Bhattacharya entre los histogramas de dicha región y los histogramas de entrenamiento tienen que superar los umbrales dados como parámetros.  
  
También devuelve una matriz de dimensiones  $[(\text{ancho\_imagen}/\text{tam\_ventana}), (\text{alto\_imagen}/\text{tam\_ventana})]$  con un 1 si la región es catalogada como piel y un 0 si no lo es. Esta matriz es necesaria para calcular el porcentaje de falsos positivos y falsos negativos.

Experimentalmente se han obtenido los umbrales para cada componente. Para la componente H es de 0.93, es decir, que para que una región se considere piel, la distancia

Bhattacharya entre el histograma de la región de la componente H y su histograma de entrenamiento debe ser mayor de 0.93. Para la componente de saturación (S) se obtuvieron dos umbrales a considerar: 0.3 y 0.4. El primero es eficaz pero sus resultados empeoran cuando las regiones de una imagen que no son piel tienen un color un parecido a ésta, puesto que lo considera piel. Sin embargo el segundo umbral (0.4) es más discriminante, pero tiene el inconveniente de que desecha algunas regiones de piel (ver las imágenes en el apartado de “Resultados Experimentales” de Kruger.jpg y de Tatuaje2.jpg).

- **DetectorPielHSV2:**

- Propósito: segmentar automáticamente las regiones de piel de una imagen.
- Entrada: imagen, tamaño de las regiones, histograma de entrenamiento de H, histograma de entrenamiento de S, umbral de H, umbral de S.
- Salida: imagen segmentada, en la que sólo se reflejan las regiones consideradas como piel y una matriz booleana.
- Descripción: es idéntico procedimiento anterior, añadiéndole la condición de que la media de la componente V de la región sea mayor que un umbral dado. Esta comparación está basada en el histograma de entrenamiento de la componente V. Como se puede observar en la figura 4.8, el histograma de la piel en la componente V es ascendente. Se puede elegir un umbral en esta componente para hacer que los valores que no lo superen no se consideren piel.




Figura 4.9 : Histograma de la componente V del espacio de color HSV

Tras varias pruebas de umbralizado se eligió un umbral de 0.4. es decir, además de cumplir las comparaciones con la distancia de Bhattacharya en H y S, el valor de la media de V en la región tratada tiene que ser mayor de 0.4. El inconveniente es que las pieles muy oscuras se pierden (entorno al 5%), pero se mejora mucho en cuanto a la detección de falsos positivos.

- **MatrizBooleanExperto:**

- Propósito: simular una segmentación realizada por una persona experta en segmentación de piel.
- Entrada: imagen, tamaño de las regiones.
- Salida: matriz booleana.
- Descripción: la entrada de este algoritmo es una imagen en la que se ha cambiado el color de la piel por un color verde que no aparece en las fotos tratadas. Esta imagen simula el reconocimiento que haría una persona experta en segmentación de piel. Este procedimiento devuelve una matriz con un uno donde encuentre una región cuyos valores sean más de la mitad de color verde y un cero en las demás.




Figura 4.10 : a) Imagen de entrada del algoritmo MatrizBooleanExperto

- b) y c) regiones en las que predomina el verde, por lo que en la matriz de salida habrá un uno
- d) y e) regiones en las que no predomina el verde, por lo que en la matriz de salida habrá un cero.

- **FalsosPosiNega:**

- Propósito: calcular los falsos positivos de una segmentación automática.
- Entrada: matriz1, matriz2.
- Salida: el número de falsos positivos y falsos negativos de la matriz2 respecto de la matriz1.
- Descripción: dada la matriz que obtendría un experto en segmentación de piel (mediante el procedimiento MatrizBooleanExperto) y la obtenida por algún procedimiento de detección de piel (por ejemplo DetectorPielHSV1) para la misma foto, calcula el número de falsos positivos y falsos negativos que hay en la imagen para el procedimiento con el que se obtuvo.

Las regiones que forman parte de los falsos positivos de una imagen son las que aparecen con un cero en la matriz obtenida por el experto en segmentación y un uno en la matriz del

algoritmo de detección de piel; mientras que las que pertenecen a los falsos negativos son las que tienen un uno en la matriz del experto y un cero en la obtenida mediante el algoritmo.

Trabajando con las matrices es:

- Matriz\_falsos posit = matriz\_automática – (matriz\_manual .\* matriz\_automática)
- Matriz\_falsos negat = matriz\_manual – (matriz\_manual .\* matriz\_automática)

El símbolo .\* simboliza un producto elemento a elemento.

Por último, basta calcular la cantidad de unos de cada matriz con el procedimiento NumUnosMatriz para saber el numero final de falsos positivos y falsos negativos.

- NumVerdes:
  - Propósito: calcular el número de píxeles verdes de una región de la imagen.
  - Entrada: imagen, esquina superior izquierda de la región, tamaño de la región.
  - Salida: número de píxeles de color verde.
  - Descripción: devuelve el número de píxeles de color verde (0, 1, 0.0039) que hay en la región indicada de la imagen. Esta función se usa en el procedimiento MatrizBooleanExperto.
- NumUnosMatriz:
  - Propósito: calcular el número de unos que hay en una matriz.
  - Entrada: matriz.
  - Salida: número de unos de la matriz.
  - Descripción: cuenta y devuelve el número de unos que hay en una matriz.

En el apartado “Resultados obtenidos” se muestran y se comentan distintas imágenes tratadas con los algoritmos de reconocimiento de piel.

## 4.6 Falsos positivos y falsos negativos

Los falsos positivos y los falsos negativos nos permiten calcular la eficacia del sistema.

- Los falsos positivos en un sistema de detección de piel automática, como es el caso de este proyecto, son aquellas regiones de la imagen que el sistema cataloga como piel sin serlo.
- Los falsos negativos son aquellas regiones de piel que el sistema cataloga como no-piel.



Figura 4.11 : a) Imagen original de CarlosSainz9.jpg, b) imagen obtenida al aplicar un algoritmo de detección de piel a la imagen anterior, donde se observan regiones de falsos positivos y falsos negativos.

Para calcular estos índices se comparan los resultados obtenidos mediante el sistema creado con los que obtendría una persona experta en segmentación de piel en imágenes. Para ello, una persona ha determinado qué regiones de una imagen son piel. Posteriormente se ha sustituido el color de la piel de estas imágenes por un color verde fácilmente reconocible y que no aparece en ninguna de las imágenes tratadas. Este color es un verde casi puro (en RGB sin normalizar es el (0, 255, 1) y en RGB normalizado es el (0, 1, 0.0039)). Tratando esta imagen con el procedimiento adecuado, obtenemos una matriz en la cual aparece el valor 1 en las regiones que esta persona catalogaría como piel y el valor 0 en las demás. Comparando esta matriz con la obtenida a partir de las imágenes logradas por medio de los algoritmos de detección de piel se hallan los falsos positivos y los falsos negativos.




Figura 4.12 : a) Imagen original de Camarera1.jpg; y b) imagen tratada de Camarera1.jpg con la piel que reconocería una persona experta en segmentación en verde.

## Capítulo 5

### Resultados experimentales

Este capítulo está dedicado a presentar los resultados más importantes obtenidos con los algoritmos desarrollados distinguiendo distintos espacios de color, YCbCr y HSV, y umbralizaciones para la distancia de Bhattacharya.

En primer lugar se exponen en unas tablas las verificaciones realizadas durante el entrenamiento para comprobar la eficacia de la distancia Bhattacharya. Estas tablas son el resultado de comparar los histogramas de cada imagen con su correspondiente de entrenamiento. También se muestran las comparaciones entre histogramas del mismo canal.

Posteriormente, se muestran los resultados obtenidos con el espacio de color YCbCr y con el HSV. El primer grupo de resultados, el de YCbCr, no es muy amplio porque, como se verá, los resultados no eran prometedores y se optó por avanzar más con el HSV. Por último, se presenta la estadística de los falsos positivos y los falsos negativos, utilizados como medida de la eficiencia de nuestro sistema.

#### 5.1 Test iniciales de verificación del entrenamiento

La distancia de Bhattacharya es el principal factor discriminante de una región de piel. Sin embargo hay histogramas de no-piel que se parecen al histograma de entrenamiento de piel, y también hay histogramas de piel que no se parecen a dicho histograma. En estos casos, es de esperar que el sistema no discrimine correctamente entre regiones de piel y no-piel. De aquí surge la necesidad de estudiar la eficacia del sistema.

En la etapa de entrenamiento se ha querido comprobar la eficacia de la distancia Bhattacharya. Es decir, acreditar que dos histogramas de imágenes de piel distintas tienen un valor de distancia de Bhattacharya alto. Para ello se realizó una prueba con veinte imágenes de las cuales se muestran las tablas resultantes. Antes de exponer dichas tablas se hace una pequeña introducción con cuatro imágenes para una mejor interpretación de las mismas. Durante ésta etapa se ha obtenido manualmente la piel de cada foto y se ha guardado independientemente (ver figuras 5.1 a 5.4). Posteriormente se ha obtenido el histograma en R, G y B de la imagen en la que



sólo aparece la piel sin contar los píxeles blancos. En las figuras 5.1 a 5.4 se representa el histograma del canal R correspondiente a cada imagen. Una vez calculados los histogramas de las veinte imágenes, se comparan con el de entrenamiento (figura 5.5) mediante distancia de Bhattacharya. También se comparan entre sí los histogramas de las distintas imágenes de sólo piel para obtener una idea de la similitud entre imágenes de sólo piel, a través de la distancia de Bhattacharya.




Figura 5.1 : a) Imagen original : Ciclistas.jpg, b) imagen de sólo la piel de la original y c) histograma de la componente R de la imagen de sólo piel




Figura 5.2 : a) Imagen original : Torero.jpg, b) imagen de sólo la piel de la original y c) histograma de la componente R de la imagen de sólo piel

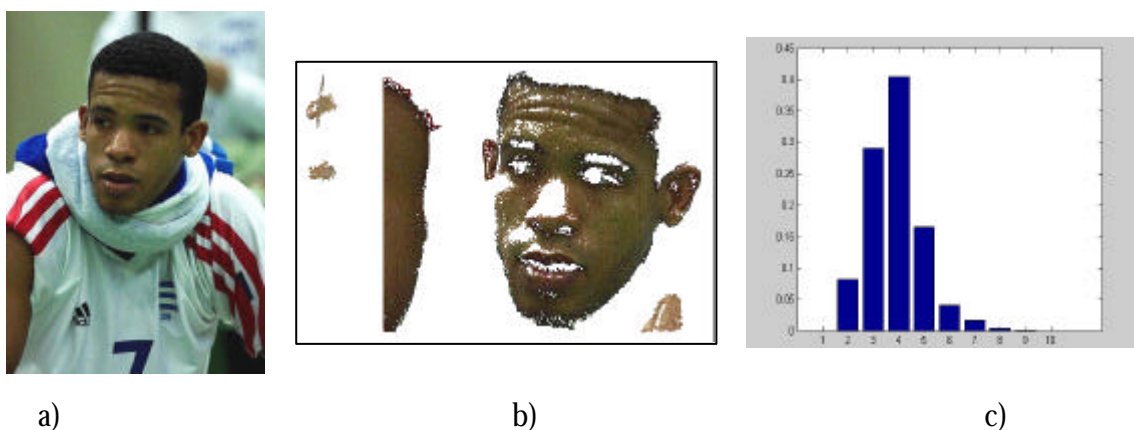


Figura 5.3 : a) Imagen original : Jugador\_voley.jpg, b) imagen de sólo la piel de la original y c) histograma de la componente R de la imagen de sólo piel




Figura 5.4 : a) Imagen original : Hombre\_triste.jpg, b) imagen de sólo la piel de la original y c) histograma de la componente R de la imagen de sólo piel




Figura 5.5 : Histograma de entrenamiento de la componente R del espacio de color RGB

Tabla 5.1 : Distancia Bhattacharya entre los histogramas de la componente R y el histograma de entrenamiento de la misma componente

Imagen	Distancia Bhattacharya
Ciclistas	0.8361
Torero	0.8555
Jugador_voley	0.4722
Hombre_triste	0.7283

Tabla 5.2 : Distancia Bhattacharya entre sí de los histogramas de la componente R

	Ciclistas	Torero	Jugador_voley	Hombre_triste
Ciclistas	1	0.4951	0.7139	0.8742
Torero		1	0.0967	0.3736
Jugador_voley			1	0.5107
Hombre_triste				1

En las tablas que se muestran a continuación se señalan los resultados que son inferiores a 0.40. Estos valores corresponden a imágenes en las cuales el histograma correspondiente tiene una distancia Bhattacharya pequeña con respecto al que se compara.

#### - Tablas en RGB

Tabla 5.3 : Distancia Bhattacharya entre el histograma de cada componente de las veinte fotos y su histograma correspondiente de entrenamiento.

	i1	i2	i3	i4	i5	i6	i7	i8	i9	i10	i11	i12	i13	i14	i15	i16	i17	i18	i19	i20
R	0.85	0.81	0.86	0.96	0.78	0.91	0.84	0.91	0.79	0.80	0.82	0.80	0.78	0.59	0.91	0.92	0.87	0.97	0.72	0.96
G	0.71	0.75	0.88	0.79	0.65	0.84	0.85	0.91	0.86	0.88	0.91	0.71	0.85	0.60	0.96	0.96	0.93	0.98	0.75	0.97
B	0.78	0.79	0.84	0.55	0.73	0.83	0.90	0.94	0.97	0.86	0.85	0.74	0.86	0.72	0.95	0.98	0.96	0.97	0.82	0.98
R*G*B	0.47	0.48	0.64	0.42	0.38	0.64	0.65	0.78	0.67	0.61	0.64	0.42	0.57	0.26	0.83	0.87	0.78	0.93	0.45	0.93

En la última fila de la Tabla 5.4 el valor mostrado es el resultado de multiplicar la distancia de Bhattacharya de las tres componentes.

Tabla 5.4 : Distancia Bhattacharya entre los histogramas de la componente R (rojo) de veinte fotos de entrenamiento (solo piel)

	i1	i2	i3	i4	i5	i6	i7	i8	i9	i10	i11	i12	i13	i14	i15	i16	i17	i18	i19	i20
i1	1																			
i2	0.94	1																		
i3	0.56	0.53	1																	
i4	0.92	0.89	0.72	1																
i5	0.63	0.55	0.52	0.76	1															
i6	0.96	0.92	0.61	0.97	0.76	1														
i7	0.89	0.85	0.50	0.92	0.78	0.96	1													
i8	0.72	0.64	0.81	0.88	0.71	0.77	0.69	1												
i9	0.43	0.37	0.97	0.61	0.49	0.50	0.42	0.74	1											
i10	0.47	0.42	0.95	0.66	0.48	0.52	0.39	0.87	0.93	1										
i11	0.43	0.38	0.94	0.67	0.59	0.53	0.46	0.84	0.95	0.96	1									
i12	0.90	0.88	0.42	0.89	0.83	0.95	0.93	0.65	0.31	0.32	0.36	1								
i13	0.77	0.73	0.65	0.79	0.50	0.73	0.59	0.85	0.52	0.73	0.63	0.62	1							
i14	0.57	0.54	0.29	0.60	0.78	0.63	0.61	0.50	0.29	0.29	0.29	0.75	0.43	1						
i15	0.77	0.74	0.87	0.86	0.56	0.77	0.62	0.93	0.77	0.89	0.81	0.61	0.89	0.43	1					
i16	0.92	0.86	0.62	0.97	0.83	0.98	0.96	0.82	0.53	0.55	0.58	0.94	0.72	0.65	0.76	1				
i17	0.98	0.95	0.60	0.94	0.62	0.95	0.85	0.79	0.45	0.54	0.48	0.88	0.83	0.58	0.84	0.91	1			
i18	0.85	0.83	0.85	0.96	0.69	0.89	0.80	0.94	0.75	0.82	0.80	0.76	0.86	0.53	0.96	0.89	0.90	1		
i19	0.87	0.84	0.39	0.82	0.72	0.92	0.95	0.50	0.25	0.18	0.25	0.95	0.46	0.63	0.46	0.89	0.80	0.66	1	
i20	0.88	0.83	0.79	0.97	0.70	0.92	0.85	0.93	0.70	0.77	0.74	0.79	0.82	0.54	0.92	0.91	0.91	0.89	0.71	1

Tabla 5.5 : Distancia Bhattacharya entre los histogramas de la componente G (verde) de veinte fotos de entrenamiento (solo piel)

	i1	i2	i3	i4	i5	i6	i7	i8	i9	i10	i11	i12	i13	i14	i15	i16	i17	i18	i19	i20
i1	1																			
i2	0.94	1																		
i3	0.46	0.50	1																	
i4	0.92	0.97	0.52	1																
i5	0.63	0.70	0.39	0.83	1															
i6	0.88	0.92	0.56	0.98	0.89	1														
i7	0.89	0.96	0.62	0.97	0.77	0.96	1													
i8	0.44	0.52	0.88	0.58	0.49	0.65	0.68	1												
i9	0.42	0.44	0.93	0.49	0.39	0.55	0.58	0.91	1											
i10	0.45	0.46	0.89	0.47	0.31	0.52	0.57	0.82	0.83	1										
i11	0.60	0.64	0.70	0.68	0.57	0.74	0.74	0.88	0.73	0.80	1									
i12	0.87	0.89	0.41	0.95	0.90	0.95	0.89	0.46	0.40	0.37	0.60	1								
i13	0.49	0.46	0.83	0.48	0.31	0.55	0.59	0.88	0.90	0.85	0.83	0.38	1							
i14	0.55	0.60	0.30	0.72	0.95	0.80	0.66	0.44	0.35	0.30	0.58	0.86	0.33	1						
i15	0.76	0.76	0.83	0.76	0.51	0.78	0.83	0.86	0.82	0.87	0.92	0.64	0.88	0.47	1					
i16	0.70	0.76	0.80	0.83	0.79	0.89	0.87	0.86	0.80	0.79	0.88	0.80	0.78	0.76	0.89	1				
i17	0.80	0.86	0.68	0.90	0.75	0.93	0.94	0.82	0.69	0.71	0.92	0.81	0.74	0.68	0.92	0.93	1			
i18	0.67	0.71	0.89	0.74	0.57	0.79	0.82	0.95	0.91	0.86	0.90	0.64	0.89	0.51	0.96	0.93	0.91	1		
i19	0.92	0.96	0.45	0.98	0.83	0.96	0.95	0.52	0.44	0.45	0.65	0.95	0.49	0.75	0.73	0.81	0.87	0.70	1	
i20	0.70	0.77	0.79	0.83	0.73	0.88	0.88	0.91	0.81	0.80	0.93	0.75	0.81	0.68	0.93	0.97	0.97	0.96	0.80	1

Tabla 5.6 : Distancia Bhattacharya entre los histogramas de la componente B (azul) de veinte fotos de entrenamiento (solo piel)

	i1	i2	i3	i4	i5	i6	i7	i8	i9	i10	i11	i12	i13	i14	i15	i16	i17	i18	i19	i20
i1	1																			
i2	0.89	1																		
i3	0.51	0.47	1																	
i4	0.66	0.87	0.99	1																
i5	0.86	0.98	0.41	0.93	1															
i6	0.83	0.92	0.49	0.84	0.94	1														
i7	0.85	0.93	0.62	0.80	0.92	0.96	1													
i8	0.63	0.63	0.81	0.34	0.55	0.66	0.77	1												
i9	0.77	0.79	0.79	0.56	0.73	0.81	0.89	0.96	1											
i10	0.61	0.52	0.89	0.22	0.43	0.50	0.63	0.82	0.78	1										
i11	0.93	0.84	0.53	0.53	0.78	0.82	0.85	0.75	0.82	0.69	1									
i12	0.82	0.91	0.37	0.86	0.94	0.97	0.93	0.53	0.71	0.40	0.81	1								
i13	0.72	0.54	0.82	0.20	0.45	0.50	0.67	0.89	0.87	0.83	0.77	0.45	1							
i14	0.69	0.83	0.32	0.76	0.85	0.92	0.90	0.57	0.69	0.38	0.74	0.94	0.40	1						
i15	0.82	0.77	0.79	0.44	0.67	0.73	0.81	0.94	0.94	0.85	0.87	0.62	0.90	0.57	1					
i16	0.76	0.80	0.78	0.57	0.75	0.86	0.92	0.91	0.95	0.78	0.85	0.78	0.80	0.79	0.91	1				
i17	0.78	0.83	0.74	0.57	0.76	0.82	0.88	0.95	0.98	0.78	0.85	0.71	0.82	0.77	0.96	0.94	1			
i18	0.74	0.72	0.89	0.45	0.64	0.72	0.83	0.96	0.96	0.87	0.79	0.60	0.91	0.57	0.97	0.94	0.95	1		
i19	0.96	0.97	0.49	0.77	0.94	0.91	0.93	0.67	0.81	0.59	0.93	0.90	0.65	0.81	0.82	0.82	0.84	0.76	1	
i20	0.76	0.79	0.77	0.54	0.73	0.83	0.90	0.96	0.98	0.79	0.85	0.74	0.84	0.74	0.94	0.98	0.98	0.96	0.82	1

## - Tablas en HSV

Tabla 5.7 : Distancia entre el histograma de cada componente de las veinte fotos y su histograma correspondiente de entrenamiento.

	i1	i2	i3	i4	i5	i6	i7	i8	i9	i10	i11	i12	i13	i14	i15	i16	i17	i18	i19	i20
H	0.95	0.95	0.97	0.96	0.69	0.94	0.98	0.96	0.94	0.94	0.94	0.95	0.96	0.76	0.97	0.99	0.94	0.96	0.97	0.96
S	0.76	0.72	0.90	0.59	0.90	0.75	0.96	0.89	0.87	0.92	0.66	0.67	0.86	0.97	0.89	0.98	0.96	0.93	0.90	0.94
V	0.85	0.81	0.86	0.96	0.78	0.91	0.84	0.91	0.79	0.80	0.82	0.80	0.78	0.60	0.91	0.92	0.87	0.97	0.72	0.96
H*S*V	0.62	0.55	0.77	0.55	0.49	0.65	0.80	0.78	0.65	0.70	0.51	0.51	0.65	0.45	0.79	0.90	0.79	0.88	0.64	0.87

En la última fila de la Tabla 5.7 el valor mostrado es el resultado de multiplicar la distancia de Bhattacharya de las tres componentes.

Se puede observar como en la Tabla 5.8 no hay valores pequeños por lo que la H puede ser un buen discriminante para el color de piel.

Tabla 5.8 : Distancia Bhattacharya entre los histogramas de la componente H (tono) de veinte fotos de entrenamiento (solo piel)

	i1	i2	i3	i4	i5	i6	i7	i8	i9	i10	i11	i12	i13	i14	i15	i16	i17	i18	i19	i20
i1	1																			
i2	0.99	1																		
i3	0.99	0.99	1																	
i4	0.99	0.99	0.99	1																
i5	0.62	0.58	0.60	0.64	1															
i6	0.99	0.99	0.99	0.99	0.57	1														
i7	0.96	0.96	0.97	0.97	0.76	0.95	1													
i8	0.99	0.99	0.99	0.98	0.56	0.99	0.96	1												
i9	0.99	0.99	0.99	0.99	0.56	0.99	0.95	0.99	1											
i10	0.99	0.99	0.99	0.99	0.60	0.99	0.96	0.99	0.99	1										
i11	0.99	0.99	0.98	0.99	0.57	0.99	0.95	0.99	0.99	0.99	1									
i12	0.99	0.99	0.99	0.99	0.62	0.99	0.96	0.99	0.99	0.99	0.99	1								
i13	0.99	0.99	0.99	0.98	0.55	0.99	0.96	0.99	0.99	0.98	0.99	0.98	1							
i14	0.70	0.68	0.70	0.71	0.83	0.67	0.78	0.67	0.66	0.69	0.67	0.70	0.67	1						
i15	0.99	0.99	0.99	0.99	0.61	0.99	0.97	0.99	0.99	0.99	0.99	0.99	0.99	0.70	1					
i16	0.95	0.94	0.97	0.95	0.66	0.94	0.97	0.96	0.94	0.94	0.93	0.95	0.96	0.73	0.97	1				
i17	0.94	0.92	0.93	0.95	0.78	0.92	0.96	0.91	0.91	0.93	0.92	0.94	0.91	0.79	0.94	0.94	1			
i18	1	0.99	0.99	0.99	0.62	0.99	0.97	0.99	0.99	0.99	0.99	0.99	0.99	0.70	0.99	0.95	0.94	1		
i19	0.98	0.97	0.98	0.99	0.71	0.97	0.99	0.97	0.97	0.98	0.97	0.98	0.97	0.76	0.98	0.97	0.97	0.98	1	
i20	0.99	0.99	0.99	0.99	0.64	0.99	0.97	0.98	0.99	0.99	0.99	0.99	0.98	0.72	0.99	0.96	0.95	0.99	0.99	1

Tabla 5.9 : Distancia Bhattacharya entre los histogramas de la componente S (saturación) de veinte fotos de entrenamiento (solo piel)

	i1	i2	i3	i4	i5	i6	i7	i8	i9	i10	i11	i12	i13	i14	i15	i16	i17	i18	i19	i20
i1	1																			
i2	0.84	1																		
i3	0.67	0.49	1																	
i4	0.47	0.83	0.29	1																
i5	0.95	0.86	0.80	0.58	1															
i6	0.73	0.94	0.47	0.91	0.80	1														
i7	0.86	0.86	0.82	0.71	0.96	0.86	1													
i8	0.77	0.59	0.88	0.37	0.88	0.56	0.86	1												
i9	0.79	0.89	0.64	0.82	0.89	0.94	0.94	0.78	1											
i10	0.80	0.67	0.91	0.43	0.87	0.61	0.87	0.84	0.73	1										
i11	0.75	0.96	0.41	0.87	0.78	0.96	0.81	0.46	0.86	0.58	1									
i12	0.74	0.97	0.41	0.91	0.78	0.96	0.82	0.48	0.87	0.59	0.98	1								
i13	0.76	0.49	0.91	0.29	0.83	0.44	0.81	0.92	0.63	0.87	0.37	0.39	1							
i14	0.79	0.68	0.91	0.49	0.90	0.68	0.93	0.88	0.80	0.92	0.62	0.61	0.90	1						
i15	0.94	0.82	0.80	0.52	0.98	0.74	0.93	0.92	0.87	0.87	0.70	0.71	0.86	0.89	1					
i16	0.70	0.66	0.92	0.57	0.85	0.69	0.93	0.87	0.81	0.90	0.60	0.62	0.88	0.95	0.84	1				
i17	0.75	0.70	0.91	0.58	0.90	0.72	0.95	0.93	0.86	0.86	0.64	0.65	0.87	0.93	0.90	0.96	1			
i18	0.78	0.62	0.95	0.41	0.90	0.58	0.90	0.97	0.77	0.90	0.52	0.54	0.95	0.93	0.92	0.93	0.97	1		
i19	0.89	0.71	0.84	0.42	0.95	0.65	0.91	0.96	0.83	0.89	0.59	0.60	0.91	0.91	0.98	0.86	0.90	0.94	1	
i20	0.83	0.78	0.81	0.62	0.95	0.80	0.96	0.94	0.94	0.84	0.71	0.71	0.83	0.91	0.95	0.90	0.95	0.92	0.95	1

## - Tablas en YCbCr

Tabla 5.10 : Distancia entre el histograma de cada componente de las veinte fotos y su histograma correspondiente de entrenamiento.

	i1	i2	i3	i4	i5	i6	i7	i8	i9	i10	i11	i12	i13	i14	i15	i16	i17	i18	i19	i20
Y	0.77	0.77	0.87	0.83	0.71	0.86	0.85	0.91	0.87	0.83	0.89	0.74	0.89	0.61	0.95	0.96	0.93	0.98	0.74	0.98
Cb	0.91	0.91	0.90	0.91	0.81	0.98	0.94	0.92	0.75	0.98	0.61	0.92	0.90	0.78	0.92	0.91	0.91	0.91	0.92	0.90
Cr	0.90	0.86	0.98	0.86	0.99	0.84	0.86	0.93	0.93	0.96	0.72	0.94	0.86	0.87	0.88	0.91	0.99	0.97	0.92	0.95
Y*Cb*Cr	0.64	0.61	0.78	0.65	0.59	0.71	0.69	0.78	0.62	0.79	0.40	0.65	0.69	0.42	0.78	0.80	0.84	0.88	0.63	0.85

En la última fila de la Tabla 5.10 el valor mostrado es el de multiplicar la distancia de Bhattacharya de las tres componentes.

En la Tabla 5.11 se observa como la imagen i11 aunque es piel su histograma no se parece al de casi ninguna otra imagen de piel, al tener la distancia de Bhattacharya muy pequeña. Esto puede ser debido a la luminancia de la imagen. Imágenes de este tipo serán un problema para el sistema creado.



Figura 5.6 : Imagen i11.jpg

Tabla 5.11 : Distancia Bhattacharya entre los histogramas de la componente Cb de veinte fotos de entrenamiento (solo piel)

	i1	i2	i3	i4	i5	i6	i7	i8	i9	i10	i11	i12	i13	i14	i15	i16	i17	i18	i19	i20
i1	1																			
i2	0.99	1																		
i3	0.99	0.99	1																	
i4	0.70	0.70	0.68	1																
i5	0.74	0.73	0.75	0.64	1															
i6	0.96	0.96	0.95	0.86	0.75	1														
i7	0.98	0.98	0.98	0.74	0.85	0.96	1													
i8	0.99	0.99	0.99	0.72	0.74	0.97	0.98	1												
i9	0.46	0.45	0.43	0.94	0.47	0.67	0.51	0.48	1											
i10	0.95	0.94	0.93	0.89	0.75	0.99	0.95	0.95	0.71	1										
i11	0.29	0.28	0.26	0.88	0.35	0.53	0.35	0.31	0.96	0.57	1									
i12	0.99	0.99	0.99	0.71	0.74	0.96	0.98	0.99	0.47	0.95	0.30	1								
i13	0.99	0.99	0.99	0.67	0.73	0.95	0.97	0.99	0.42	0.93	0.25	0.99	1							
i14	0.75	0.75	0.77	0.58	0.99	0.74	0.86	0.76	0.38	0.73	0.26	0.76	0.75	1						
i15	1	0.99	0.99	0.71	0.74	0.96	0.98	0.99	0.46	0.95	0.29	1	0.99	0.75	1					
i16	0.99	0.99	0.99	0.69	0.75	0.96	0.98	0.99	0.44	0.94	0.27	0.99	0.99	0.77	0.99	1				
i17	0.99	0.99	0.99	0.68	0.75	0.95	0.98	0.99	0.43	0.94	0.26	0.99	0.99	0.77	0.99	0.99	1			
i18	0.99	0.99	0.99	0.69	0.75	0.96	0.98	0.99	0.44	0.94	0.27	0.99	0.99	0.77	0.99	1	0.99	1		
i19	0.99	0.99	0.99	0.70	0.79	0.96	0.99	0.99	0.45	0.94	0.28	0.99	0.99	0.81	0.99	0.99	0.99	0.99	1	
i20	0.99	0.99	0.99	0.68	0.73	0.95	0.97	0.99	0.43	0.94	0.26	0.99	0.99	0.75	0.99	0.99	0.99	0.99	0.99	1

Tabla 5.12 : Distancia Bhattacharya entre los histogramas de la componente Cr de veinte fotos de entrenamiento (solo piel)

	i1	i2	i3	i4	i5	i6	i7	i8	i9	i10	i11	i12	i13	i14	i15	i16	i17	i18	i19	i20
i1	1																			
i2	0.99	1																		
i3	0.91	0.87	1																	
i4	0.98	0.99	0.85	1																
i5	0.88	0.84	0.97	0.84	1															
i6	0.99	0.99	0.85	0.99	0.82	1														
i7	0.60	0.52	0.86	0.49	0.85	0.49	1													
i8	0.73	0.66	0.94	0.63	0.92	0.63	0.98	1												
i9	0.99	0.98	0.94	0.97	0.92	0.97	0.65	0.77	1											
i10	0.98	0.95	0.97	0.94	0.95	0.94	0.74	0.95	0.99	1										
i11	0.93	0.96	0.72	0.97	0.70	0.97	0.29	0.46	0.91	0.85	1									
i12	0.99	0.97	0.95	0.96	0.92	0.97	0.68	0.80	0.99	0.89	0.89	1								
i13	0.61	0.54	0.87	0.51	0.86	0.50	0.99	0.98	0.66	0.75	0.31	0.70	1							
i14	0.76	0.73	0.86	0.71	0.88	0.71	0.76	0.81	0.79	0.82	0.59	0.80	0.76	1						
i15	0.99	0.99	0.90	0.98	0.86	0.99	0.56	0.70	0.99	0.97	0.95	0.98	0.58	0.75	1					
i16	0.69	0.61	0.92	0.59	0.90	0.58	0.99	0.99	0.73	0.81	0.40	0.76	0.99	0.80	0.65	1				
i17	0.94	0.90	0.99	0.89	0.97	0.88	0.83	0.91	0.96	0.98	0.77	0.97	0.84	0.84	0.92	0.89	1			
i18	0.85	0.80	0.99	0.77	0.96	0.78	0.92	0.97	0.88	0.93	0.62	0.90	0.93	0.84	0.83	0.96	0.97	1		
i19	0.71	0.64	0.93	0.61	0.91	0.61	0.98	0.99	0.75	0.83	0.43	0.78	0.99	0.80	0.68	0.99	0.90	0.97	1	
i20	0.98	0.96	0.97	0.95	0.94	0.95	0.72	0.83	0.99	0.99	0.86	0.99	0.73	0.81	0.97	0.80	0.98	0.93	0.81	1

NOTA: Los histogramas en V de HSV e Y de YCbCr no están comparados porque éstas componentes dependen de la luz de la imagen, es decir, reflejan la luminancia de la misma.

## 5.2 Resultados obtenidos en los espacios de color YCbCr y HSV

### Resultados en YCbCr



Figura 5.7: a) Imágenes originales. Imágenes tratadas con el algoritmo DetectorPielYCbCr con los siguientes umbrales para Cb y Cr: b) 0.8 y 0.0, c) 0.9 y 0.5, d) 0.0 y 0.8, e) 0.5 y 0.9, f) 0.8 y 0.8, respectivamente. Todas con un tamaño de región de 20\*20 píxeles



## Resultados en HSV

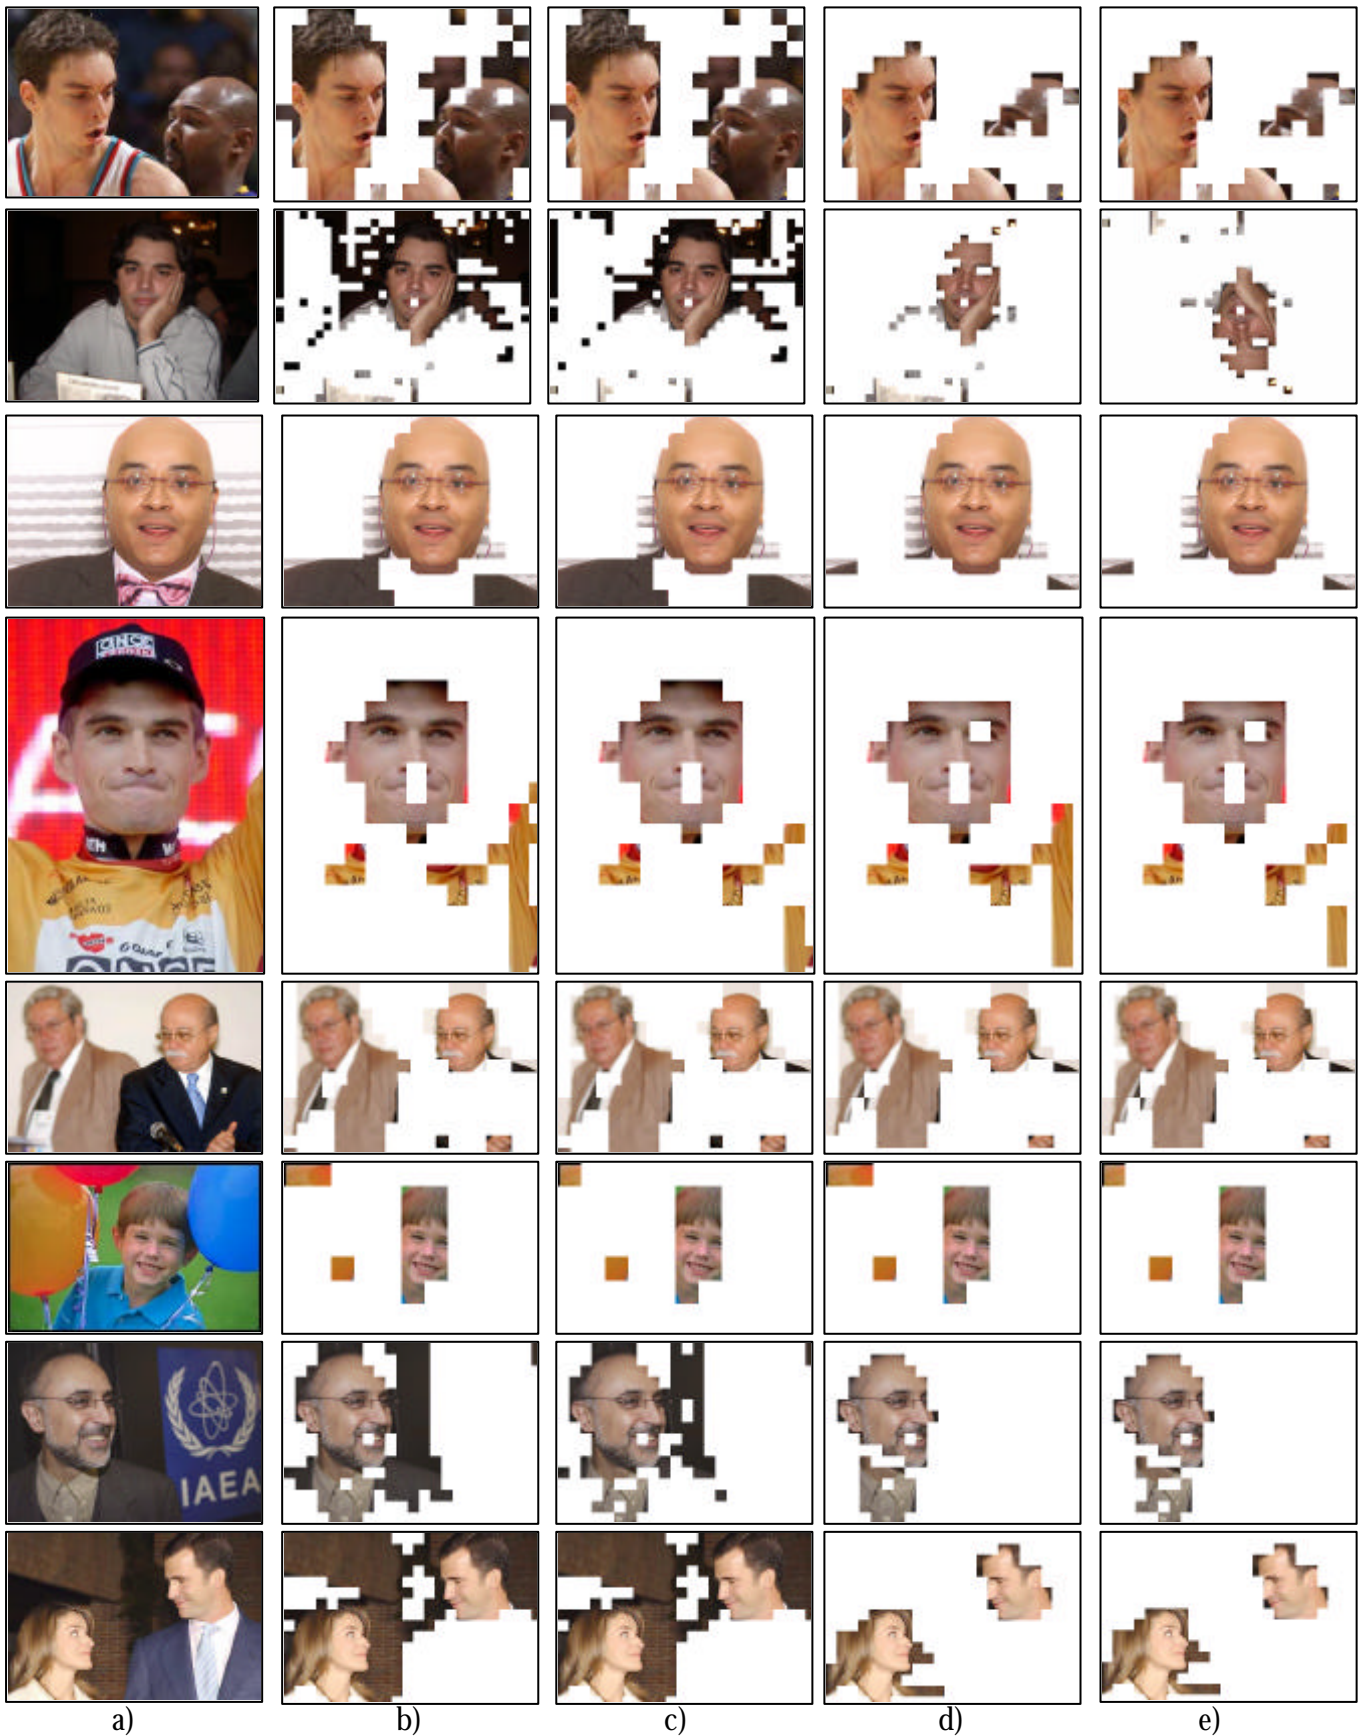


Figura 5.8: a) Imágenes originales, b) y c) imágenes tratadas con el algoritmo DetectorPielHSV1 con umbral S de 0.3 y 0.4, respectivamente, d) y e) imágenes tratadas con el algoritmo DetectorPielHSV2 con umbral S de 0.3 y 0.4 respectivamente. Ambos algoritmos con umbral H = 0.93 y tamaño de región de 20\*20 píxeles



a) b) c) d) e)

Figura 5.9: a) Imágenes originales, b) y c) imágenes tratadas con el algoritmo DetectorPielHSV1 con umbral S de 0.3 y 0.4, respectivamente, d) y e) imágenes tratadas con el algoritmo DetectorPielHSV2 con umbral S de 0.3 y 0.4 respectivamente. Ambos algoritmos con umbral H = 0.93 y tamaño de región de 10\*10 píxeles



En las figuras de este apartado, la columna a) está dedicada a la imagen original, mientras que en las demás se expone dicha imagen tratada.

En la figura 5.7 podemos observar algunos de los resultados obtenidos con el espacio de color YCbCr. En las columnas de la b) a la f) están las imágenes obtenidas mediante el algoritmo DetectorPielYCbCr con distintos umbrales. El tamaño de la región a tratar es en todos los casos de 20\*20 y los umbrales usados para Cb y Cr han sido los siguientes: b) 0.8 y 0.0, c) 0.9 y 0.5, d) 0.0 y 0.8, e) 0.5 y 0.9, f) 0.8 y 0.8, respectivamente.

En las figura 5.8 y 5.9 se exponen imágenes tratadas con los algoritmos DetectorPielHSV1 (columnas b) y c) ) y DetectorPielHSV2 (columnas d) y e) ). Los umbrales usados han sido: para H de 0.93 en todas las columnas y para S de 0.3 para las columnas b) y d), y de 0.4 para c) y e). Conviene recordar que la diferencia entre estos algoritmos de detección de piel en HSV es que DetectorPielHSV2 tiene en cuenta el valor medio de V en la región. Por lo que las columnas d) y e) además de los umbrales mencionados tienen que tener un valor medio de V mayor de 0.4.

La única diferencia entre las figuras 5.8 y 5.9 es el tamaño de la región considerada: en la figura 5.8 el tamaño de la región es de 20\*20 píxeles, mientras que en la figura 5.9 es de 10\*10.

### 5.3 Análisis estadístico

Una manera cuantitativa de verificar si los resultados obtenidos por los algoritmos desarrollados son aceptables, se basa en el estudio de los falsos positivos y los falsos negativos de un número razonable de imágenes tratadas con el mismo algoritmo.

A continuación se muestran dos tablas con los porcentajes de falsos positivos y falsos negativos de los algoritmos DetectorPielHSV1 y DetectorPielHSV2. Los umbrales utilizados en cada caso son los siguientes:

Umbrales del algoritmo DetectorPielHSV1:

- El valor de la componente H ha de superar el umbral de 0.93 en la distancia de Bhattacharya.
- El valor para la componente S ha de superar el umbral de 0.3 y 0.4 en la distancia de Bhattacharya, para la subtabla de la derecha y de la izquierda respectivamente.

Umbrales del algoritmo DetectorPielHSV2:

- El valor de la componente H ha de superar el umbral de 0.93 en la distancia de Bhattacharya.

- El valor para la componente S ha de superar el umbral de 0.3 y 0.4 en la distancia de Bhattacharya, para la subtabla de la derecha y de la izquierda respectivamente
- El valor medio de la componente V en la región analizada ha de ser mayor que el umbral 0.4. Con esto se pierden algunas pieles muy oscuras pero se obtiene una cantidad considerablemente menor de falsos positivos

Tabla 5.13: Tabla de los falsos positivos y los falsos negativos del algoritmo DetectorPielHSV1. Resultados en % (tanto por ciento)

Nombre de la imagen	Umbral de Tono (H) = 0.93			
	Umbral de Saturación (S) = 0.3		Umbral de Saturación (S) = 0.4	
	Falsos Positivos	Falsos Negativos	Falsos Positivos	Falsos Negativos
Brett	10.8859	0.9760	9.0841	6.4565
Manuel	12.2105	2.5263	11.3684	2.5263
Piernas3	6.2222	1.3333	5.7778	1.7778
Rubia	13.0594	2.7146	11.8122	6.3830
Smile	5.1613	0	5.1613	0
Camarera1	7.6522	0.8696	7.5652	0.8696
Daniel05	8.2031	0.6510	7.9427	0.6510
Javi	5.0896	0.3584	0.0896	1.5054
Beckham2	14.8148	0.1058	13.8624	0.1058
Beckham7	14.6032	0.7407	14.4974	1.3757
Beckham8	5.8201	0	5.3968	0.2116
Beckham13	3.1613	0.5161	2.5161	0.6452
CarlosSainz9	6.1084	0.6863	5.0789	1.5831
Mama_pisci	1.9048	0	1.9048	0
Foto008	15.5280	0	13.5404	0
Foto038	5.8594	2.2604	5.8594	0.2604
Foto065	10.5590	0.2484	9.8137	0.2484
Foto243	9.6354	0.3906	8.4635	2.0833
Foto329	1.5625	1.3021	1.5625	2.0833
Principe13	12.5161	0	12.5161	0
Cloony3	9.9379	0.3106	9.9379	2.6398
Cloony10	9.0062	0.1553	9.0062	0.4658
Cloony15	17.3333	1.3333	14.8333	11.3333
HijoSadam1	11.3043	2.7329	10.8075	5.9627
CiclismoB17	3.0914	1.1425	2.8898	1.4785
Media de las 25 imágenes	8.8492	0.8542	8.0515	2.0259

Tabla 5.14: Tabla de los falsos positivos y los falsos negativos del algoritmo DetectorPielHSV2. Resultados en % (tantos por ciento)

Nombre de la imagen	Umbral de Tono (H) = 0.93 Umbral de Intensidad (V) = 0.4			
	Umbral de Saturación (S) = 0.3		Umbral de Saturación (S) = 0.4	
	Falsos Positivos	Falsos Negativos	Falsos Positivos	Falsos Negativos
Brett	9.9099	0.9760	8.6336	6.4565
Manuel	6.9474	2.5263	6.1053	2.5263
Piernas3	4.8889	1.3333	4.4444	1.7778
Rubia	11.2252	2.8613	10.6383	6.3830
Smile	4.6452	0	4.6452	0
Camarera1	7.4783	0.8696	7.3913	0.8696
Daniel05	1.8229	5.4588	1.5625	5.4688
Javi	0.7168	1.6487	0.7168	2.7957
Beckham2	6.7725	0.1058	6.6667	0.1058
Beckham7	10.2646	0.8466	10.1587	1.4815
Beckham8	4.9735	0	4.5503	0.2116
Beckham13	2.1935	0.5161	2.0645	0.6452
CarlosSainz9	5.9025	0.6863	4.8730	1.8531
Mama_pisci	1.7460	0	1.7460	0
Foto008	5.8385	0	5.8385	0
Foto038	0.9115	2.4740	0.9115	2.4740
Foto065	4.4720	0.3727	4.3478	0.3727
Foto243	4.5573	3.6458	4.1667	5.9896
Foto329	0.2604	7.0313	0.2604	7.8125
Principe13	8.2581	0	8.2581	0
Cloony3	7.9193	0.7764	7.9193	3.1056
Cloony10	8.2298	0.1553	8.2298	0.4658
Cloony15	9.5000	1.833	8.8333	11.3333
HijoSadam1	9.9379	2.7329	9.4410	5.9627
CiclismoB17	1.3021	1.5625	1.3021	1.5625
Media de las 25 imágenes	5.6269	1.5369	5.3482	2.7729

Se observa que el número de falsos positivos y falsos negativos es razonablemente pequeño. También se aprecia que el algoritmo DetectorPielHSV2 (Tabla 5.14) produce un número menor de falsos positivos que el algoritmo DetectorPielHSV1 (Tabla 5.13), pero el número de falsos negativos es mayor. El algoritmo DetectorPielHSV2 es más eficiente cuando lo que no es piel tiene un color similar, debido a que es más discriminante que el algoritmo DetectorPielHSV1 al tener umbral en la intensidad (V). Sin embargo, este algoritmo no da tan buenos resultados cuando en una imagen hay varias tonalidades de piel.

Las figura 5.10 muestra un ejemplo sobre la Tabla 5.14, en el que el rendimiento obtenido con un umbral de saturación de 0.4 (subtabla de la derecha) es bastante inferior al logrado con un umbral de 0.3 (subtabla de la izquierda).




Figura 5.10 : a) Tatuaje2.jpg (Imagen original), b) Imagen tratada con un umbral de saturación (S) de 0.3, y c) imagen obtenida con un umbral de saturación (S) de 0.4, además del umbral de 0.93 y de 0.4 para la H y la V respectivamente

En la figura 5.11 la mejora de poner el umbral de saturación a 0.4 es bastante notable, reduciendo los falsos positivos en un 32% de los obtenidos con un umbral de 0.3, sin que afecte al número de falsos negativos (cero con ambos umbrales).




Figura 5.11 : a) kruger.jpg (Imagen original), b) imagen tratada con un umbral de saturación (S) de 0.3, y c) imagen obtenida con un umbral de saturación (S) de 0.4, además del umbral de 0.93 y 0.4 para la H y la V respectivamente

## Capítulo 6

### Conclusiones y futuras líneas

#### Conclusiones:

1. Se ha coleccionado una base de datos de 2.737 imágenes a color, suficientes para el desarrollo del proyecto. Esta base de datos es lo suficientemente amplia como para ser utilizada en futuros trabajos relacionados.
2. El autor se ha familiarizado con el marco de trabajo de la Visión Artificial, prestando una especial atención a todo lo referente al tratamiento de imágenes a color. Además se ha aprendido a utilizar la herramienta de programación Matlab 6.1.
3. Se ha creado una *toolbox* de funciones Matlab que permite el entrenamiento de un sistema de detección del color de la piel en imágenes a color basado en el análisis de histogramas.
4. Se ha llevado a cabo el entrenamiento del sistema con ayuda de los algoritmos mencionados y un subconjunto de las imágenes de la base de datos. Como resultado se han obtenido diferentes histogramas de entrenamiento, en concreto uno por cada canal de cada espacio de color considerado.
5. Se ha creado una *toolbox* de funciones Matlab que permite la detección del color de la piel en imágenes a color basado en el análisis de histogramas, utilizando para ello los histogramas obtenidos durante la etapa de entrenamiento.
6. Como consecuencia del análisis de los resultados obtenidos, se han propuesto y probado mejoras en los algoritmos desarrollados.
7. Se ha observado que el comportamiento de los algoritmos desarrollados es diferente en función de las imágenes consideradas. Los algoritmos con umbrales más restrictivos dan mejores resultados en imágenes con fondo similar al color de la piel. En el resto de las imágenes producen una alta tasa de falsos negativos. Los algoritmos con umbrales menos restrictivos dan mejores resultados en imágenes con poca posibilidad de confusión. En el resto de imágenes (imágenes con fondo similar al color de la piel) producen una tasa mayor de falsos positivos.
8. El análisis estadístico de los resultados muestra que el nivel de éxito del sistema es aceptable. En concreto, se han desarrollado algoritmos que consiguen una tasa de

falsos positivos del 5.3 % y de falsos negativos del 2.8 % basándose en análisis de regiones y umbralización de la luminancia.

#### Futuras líneas:

1. Una posible mejora del sistema se podría realizar en la etapa de entrenamiento, entrenando al sistema con un número mayor de imágenes para que tenga una mayor experiencia a la hora de detectar regiones de piel.
2. El sistema desarrollado puede ser extendido a la segmentación de la piel en secuencia de imágenes.
3. En el contexto de las secuencias de imágenes, el sistema desarrollado puede ser utilizado para el cálculo de pesos en algoritmos de seguimiento como el filtro de partículas.
4. Finalmente, se considera que el modelo propuesto puede ser útil por su aplicación en sistemas control de acceso a páginas web cuyo contenido sea inadecuado para internautas infantiles.

## Bibliografía

- [Ahlberg 1999] AHLBERG, J. 1999. A system for face localization and facial feature extraction. Tech. Rep. LiTH-ISY-R-2172, Linköping University.
- [Birchfield 1998] BIRCHFIELD, S. 1998. Elliptical head tracking using intensity gradients and color histograms. In *Proceedings of CVPR '98*, 232-237.
- [Brand and Mason 2000] BRAND, J., AND MASON, J. 2000. A comparative assessment of three approaches to pixellevel human skin-detection. In *Proc. of the International Conference on Pattern Recognition*, vol. 1, 1056-1059.
- [Brown et al. 2001] BROWN, D., CRAW, I., AND LEWTHWAITE, J. 2001. A som based approach to skin detection with application in real time systems. In *Proc. of the British Machine Vision conference*, 2001.
- [Chai and Bouzerdoum 2000] CHAI, D., AND BOUZERDOUM, A. 2000. A bayesian approach to skin color classification in ycbcr color space. In *Proceedings IEEE Region Ten Conference (TENCON '2000)*, vol. 2, 421-424.
- [Chen et al. 1995] CHEN, Q., WU, H., AND YAHCIDA, M. 1995. Face detection by fuzzy pattern machining. In *Proc. of the Fifth International Conference on Computer Vision*, 591-597.
- [Esqueda 2002] ESQUEDA, J.J. 2002. Fundamentos de procesamiento de imágenes. CONACTEC 2002. Instituto Tecnológico de Ciudad Madero. México.
- [Fleck et al. 2002] FLECK, M., FORSYTH, D. A., AND BREGLER, C. 2002. Finding naked people. In *Proc. of the ECCV*, vol. 2, 592 – 602.
- [García et al. 2001] GARCÍA, J., RODRÍGUEZ, J. I., BRAZÁLEZ, A. 2001. Aprende Matlab 6.1 como si estuviera en primero. E. T. S. I. Industriales. Universidad Politécnica de Madrid.
- [Gomez 2000] GOMEZ, G. 2000. On selecting colour components for skin detection. In *Proc. of the ICPR*, vol. 2, 961 – 964.
- [Gomez and Morales 2002] GOMEZ, G., AND MORALES, E. 2002. Automatic feature construction and a simple rule induction algorithm for skin detection. In *Proc. of the ICML Workshop on Machine Learning in Computer Vision*, 31 – 38.
- [Hsu et al. 2002] HSU, R. L., ABDEL-MOTTALEB, M., AND JAIN, A. K. 2002. Face detection in color images. *IEEE Trans. Pattern Analysis and Machine Intelligence* 24, 5, 696 – 706.
- [Jedynack et al. 2002] JEDYNACK, B., ZHENG, H., DAOUDI, M., AND BARRET, D. 2002. Maximum entropy models for skin detection. Tech. Rep. XIII, Université des Sciences et Technologies de Lille, France.
- [Jones and Rehg 1999] JONES, M. J., AND REHG, J. M. 1999. Statistical color models with application to skin detection. In *Proc. of the CVPR'99*, vol. 1, 274 – 280.
- [Jordao et al. 1999] JORDAO, L., PERRONE, M., COSTEIRA, J., AND SANTOS-VICTOR, J. 1999. Active face and feature tracking. In *Proceeding of the 10<sup>th</sup> International Conference on Image Analysis and Processing*, 572 – 577.
- [Lee and Yoo 2002] LEE, J. Y., AND YOO, S. I. 2002. An elliptical boundary model for skin color detection. In *Proc. of the 2002 International Conference on Imaging Science, Systems, and Technology*.
- [McKenna et al. 1998] MCKENNA, S., GONG, S., AND RAJA, Y. 1998. Modelling facial colour and identity with gaussian mixtures. *Pattern Recognition* 31, 12, 1883 – 1892.
- [Menser and Wien 2000] MENSER, B., AND WIEN, M. 2000. Segmentation and tracking of facial regions in color image sequences. In *Proc. SPIE Visual Communications and Image Processing 2000*, 731 – 740.
- [Oliver et al. 1997] OLIVER, N., PENTLAND, A., AND BERARD, F. 1997. Lafter: Lips and face real time tracker. In *Proc. Computer Vision and Pattern Recognition*, 123 – 129.

[Peer et al. 2003] PEER, P., KOVAC, J., AND SOLINA, F. 2003. Human skin colour clustering for face detection. In *submitted to EUROCON 2003 – International Conference on Computer as a Tool*.

[Phung et al. 2002] PHUNG, S. L., BOUZERDOUM, A., AND CHAI, D. 2002. A novel skin color model in ycbcr color space and its application to human face detection. In *IEEE International Conference on Image Processing (ICIP'2002)*, vol.1, 289 – 292.

[Prádanos et al. 2002] PRÁDANOS, R., SANZ, J. M., DOMÍNGUEZ, M., ESPINOSA, M. 2002. Perspectivas de futuro en la variable color en ingeniería gráfica. En *XIV Congreso Internacional de Ingeniería Gráfica*. Santander.

[Saber and Tekalp 1998] SABER, E., AND TEKALP, A. 1998. Frontal-view face detection and facial feature extraction using color, shape and symmetry based cost functions. In *Pattern Recognition Letters*, vol.9, 669 – 680.

[Schied 1997] SCHIED, A., 1997. Geometric aspects of Fleming-Viot and Dawson-Watanabe processes. Humboldt-Universität zu Berlin. In *The annals of Probability*, 1997, vol. 25, N° 3, 1160 – 1179.

[Schumeyer and Barner 1998] SCHUMEYER, R., AND BARNER, K. 1998. A color-based classifier for region identification in video. In *Visual Communications and Image Processing 1998*, SPIE, vol. 3309, 189 – 200.

[Sigal et al. 2000] SIGAL, L., SCLAROFF, S., AND ATHITSOS, V. 2000. Estimation and prediction of evolving color distributions for skin segmentation under varying illumination. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition*, vol. 2, 152 – 159.

[Soriano et al. 2000] SORIANO, M., HUOVINEN, S., MARTINKAUPPI, B., AND LAAKSONEN, M. 2000. Skin detection in video under changing illumination conditions. In *Proc. 15<sup>th</sup> International Conference on Pattern Recognition*, 249 – 255.

[Srihari et al. 2003] SRIHARI, S., TOMAI, C., ZHANG, B., AND LEE, S. 2003. Individuality of Numerals. In *Proc. Of the Seventh International Conference of Document Analysis and Recognition (ICDAR 2003)*.

[Terrillon et al. 2000] TERRILLON, J. C., SHIRAZI, M. N., FUKAMACHI, H., AND AKAMATSU, S. 2000. Comparative performance of different skin chrominance models and chrominance spaces for the automatic detection of human faces in color images. In *Proc. of the International Conference on Face and Gesture Recognition*, 54 – 61.

[Vélez et al. 2003] VÉLEZ, J., SANCHEZ, A., MORENO, A. B., ESTEBAN, J. L. 2003. Visión por computador. Dykinson S. L.

[Vezhnevets et al. 2003] VEZHNEVETS, V., SAZONOV, V., AND ANDREEVA, A. 2003. A Survey on Pixel-Based Skin Color Detection Techniques. In *Proc. Graphicon-2003*, pp. 85 – 92. Moscow, Rusia.

[Vicente et al. 2004] VICENTE, C., GARCÍA, G., GARCÍA, A. 2004. Seguimiento de caras humanas mediante búsqueda logarítmica en rejilla. Dept. Tecn. de la Información y las Comunicaciones. Univ. Politécnica de Cartagena.

[Yang and Ahuja 1998] YANG, M. H., AND AHUJA, N. 1998. Detecting human faces in color images. In *International Conference on Image Processing (ICIP)*, vol. 1, 127 – 130.

[Yang and Ahuja 1999] YANG, M. H., AND AHUJA, N. 1999. Gaussian mixture model for human skin color and its application in image and video databases. In *Proc. of the SPIE: Conf. on Storage and Retrieval for Image and Video Databases (SPIE 99)*, vol. 3656, 458 – 466.

[Zarit et al. 1999] ZARIT, B. D., SUPER, B. J., AND QUEK, F. K. H. 1999. Comparison of five color models in skin pixel classification. In *ICCV'99 Int'l Workshop on recognition, analysis and tracking of face and gestures in Real-Time systems*, 58 – 63.

[web1] <http://energiaycomputacion.univalle.edu.co/edicion14.html#introduccion>

[web2] [www.adobe.es/products/photoshop/main.html](http://www.adobe.es/products/photoshop/main.html)

[web3] [www.desarrolloweb.com/articulos/imprimir.php?id=1503](http://www.desarrolloweb.com/articulos/imprimir.php?id=1503)

[web4] [www.gig.etsii.upm.es/pdf/doctorado/EL%20COLOR.pdf](http://www.gig.etsii.upm.es/pdf/doctorado/EL%20COLOR.pdf)

[web5] [www.mathworks.com](http://www.mathworks.com)