

# Segmentación de regiones de interés en imágenes médicas

Mariana del Fresno<sup>1,2</sup>, Mario Moreno<sup>1</sup>, Marcelo Vénere<sup>1,2</sup>

<sup>1</sup>Universidad Nacional del Centro, Pinto 399, 7000 Tandil

<sup>2</sup>PLADEMA-ISISTAN

## Resumen

*La habilidad de detectar estructuras homogéneas dentro de una imagen constituye un aspecto fundamental para la automatización de diverso tipo de aplicaciones en el área de la medicina. Entre los enfoques de segmentación propuestos para resolver este problema, el método de crecimiento de regiones es uno de los más simples y robustos, ya que permite la inclusión de diferentes criterios de evaluación de similitud de los elementos de la imagen y además posibilita la inclusión de información adicional sobre las características de la imagen y de las diferentes estructuras de interés a detectar dentro de la misma. En este trabajo se describe una estrategia de segmentación de imágenes tridimensionales basada en la integración del crecimiento de regiones con información sobre bordes, enfoque que permite reducir los inconvenientes originados en el proceso de segmentación, cuando se utilizan ambos criterios por separado. Se provee además un ambiente de visualización que permite explorar la imagen y evaluar el resultado de la segmentación. Los algoritmos se complementan con la posibilidad de extraer características de las regiones detectadas, aspecto de suma utilidad en diverso tipo de aplicaciones. Los resultados obtenidos sobre imágenes médicas muestran que la estrategia planteada permite obtener segmentaciones de calidad muy aceptable y con costo reducido, superando algunas dificultades en las que otras técnicas comúnmente fallan.*

## Palabras Clave

Segmentación de imágenes, Crecimiento de regiones, Visualización tridimensional, Imágenes médicas

## Introducción

La evolución de la tecnología computacional ha transformado considerablemente las características del tratamiento de las imágenes médicas a partir del surgimiento de las diferentes modalidades, como tomografía computada (CT) o imágenes de resonancia magnética (MRI), entre otras [1]. En particular, la habilidad de detectar estructuras con características similares dentro de una imagen constituye un aspecto fundamental del procesamiento de imágenes. Este proceso, conocido como segmentación de imágenes, desempeña un rol sumamente importante en diversas áreas de aplicación y generalmente constituye el paso previo al análisis y visualización de las imágenes, por lo que su resultado influye en el de los procesos subsiguientes. Diversos procedimientos médicos han incorporado estos procedimientos computacionales a sus estudios, facilitando o complementando la tarea de los especialistas, por ejemplo en el diagnóstico de patologías o en la planificación de tratamientos de radioterapia o de cirugías [2].

Uno de los grandes retos que ofrece el procesamiento de imágenes médicas es el poder definir con exactitud el límite de cada estructura anatómica de interés. El ruido, los cambios graduales de intensidades o la similitud de intensidades entre diferentes tejidos, provoca que la definición de los límites de cada tejido sea una tarea difícil. Por otra parte, a pesar de que se han propuesto numerosas soluciones computacionales aplicables al problema de la segmentación en diversas áreas, actualmente en medicina esta tarea aún se suele efectuar manualmente, a través de una delimitación de las regiones de interés mediante

especificación de puntos frontera sobre los cortes digitales [3]. Esta práctica es altamente subjetiva y costosa, tanto en tiempo como en esfuerzo, y además los resultados no son fácilmente repetibles. Por este motivo, se ha vuelto sumamente necesario el desarrollo de facilidades de segmentación automática o semi-automática que puedan asistir convenientemente al usuario, permitiendo su intervención como experto, aunque restringida a aquellas situaciones en que puede ser provista en una forma simple y robusta [4].

Los métodos de segmentación se pueden agrupar en diferentes esquemas de clasificación. En un sentido amplio se pueden considerar tres tipos principales: esquemas de agrupamiento de puntos, métodos basados en bordes y métodos orientados a regiones [5,6]. Además, se han propuesto esquemas híbridos que resultan de combinaciones de los enfoques anteriores.

El primer tipo de métodos se basa en la partición de los elementos de la imagen sólo en base a la información sobre sus tonalidades, de acuerdo a si se encuentran entre valores de umbral especificados (por lo que se conocen como métodos de *thresholding*). En ciertos casos, el análisis de la distribución de intensidades de la imagen permite encontrar de manera óptima los valores característicos que establecen la separación de los objetos de interés, básicamente en zonas correspondientes a valles en el histograma de intensidades de la imagen global o en histogramas locales. Sin embargo, suelen presentarse problemas cuando tales valles no son fácilmente identificables, indicando en este caso que las intensidades de los objetos se superponen. Otro aspecto frecuente es la variación de intensidades en el fondo o incluso dentro de los mismos objetos. En tales casos, un umbral adecuado para un área de la imagen puede funcionar pobremente en otros sectores de la misma, por lo cual se han propuesto soluciones mediante umbrales dinámicos.

Los métodos basados en bordes realizan la detección de transiciones de tonalidades entre puntos de diferentes componentes. Idealmente, los bordes deberían corresponder a los límites entre objetos homogéneos y superficies de objetos. Si bien se han planteado numerosas variantes, hay dos enfoques principales dentro de esta clase de métodos y son el uso de la primera o segunda derivada a través del empleo de máscaras tales como las de Roberts o Sobel [7] o el enfoque propuesto por Canny [8]. La generalización isotrópica de la segunda derivada es el Laplaciano [5]. Luego de aplicar alguno de los filtros, usualmente prosigue una etapa de conexión de los bordes encontrados para formar curvas o superficies conectadas. Esto es necesario debido a que, excepto en el caso de imágenes simples libres de ruido, la detección de bordes generalmente resulta en un conjunto de elementos de borde fragmentados. La naturaleza derivativa de este enfoque lo hace extremadamente sensible a la presencia de ruido en la imagen y además los bordes detectados no siempre resultan continuos, dificultando la determinación de las regiones dentro de los límites hallados.

Contrariamente a los métodos anteriores, los enfoques basados en regiones permiten considerar tanto la similitud de intensidades como la conectividad de los elementos, razón por la cual constituyen una de las alternativas más robustas y a la vez simples. En un esquema de crecimiento de regiones, los objetos de interés dentro de la imagen se constituyen a partir de puntos iniciales (conocidos como semillas), y evolucionan mediante la incorporación sucesiva de los puntos próximos y similares a los que ya han sido incluidos en cada región. El proceso de crecimiento continúa de esta manera hasta no se encuentran más puntos en condiciones de integrarse a las regiones [5, 9].

Los diferentes métodos de segmentación propuestos en los últimos años intentan efectuar la partición de la imagen basándose en alguno de los criterios anteriores. Las dos

últimas estrategias son complementarias y en una imagen simple con componentes homogéneas bastaría emplear una de las dos alternativas. Sin embargo, en medicina como en otros campos de aplicación, las imágenes comúnmente suelen ser complejas y pueden contener ruido debido a las características de los dispositivos y del proceso de captura, y las intensidades de las diferentes estructuras presentan variaciones de contraste. La utilización de estas técnicas de manera combinada puede aumentar la robustez al sistema. Por tal motivo, la tendencia actual se enfoca hacia la integración de ambos enfoques, basada en la naturaleza complementaria de la información sobre regiones y bordes, a fin de obtener mejores resultados y resolver los problemas que ambos métodos poseen cuando son usados individualmente [10].

En este trabajo se presenta un ambiente para la visualización y segmentación de imágenes digitales tridimensionales, el cual puede ser de valiosa asistencia en diversas aplicaciones médicas. Se propone una estrategia basada en el uso complementario del criterio de crecimiento de regiones y el empleo de información sobre los bordes durante el proceso de segmentación, integración que permite reducir algunos de los problemas básicos de la segmentación tradicional. Por lo general, en los esquemas convencionales de crecimiento de regiones, la ubicación de las semillas y el indicador de homogeneidad para cada región deben ser provistos por el usuario, así como otros parámetros requeridos por el algoritmo. Lo primero no se considera problemático, ya que el especialista posee el conocimiento experto sobre la composición anatómica necesario para indicar puntos característicos de la estructura a segmentar y sí es una tarea dificultosa de llevar a cabo en forma automática. Sin embargo, especificar un criterio de similitud puede resultar sumamente complicado para el profesional médico ya que su concepto de homogeneidad puede ser difuso y no fácilmente traducible a un criterio computacional [11]. Además, tal criterio suele depender por lo general de las características de la región a detectar y además resulta sumamente variable entre diferentes imágenes. Por estas razones, en este trabajo se ha adoptado una determinación de semillas a través de una interface visual de fácil utilización por parte del usuario. A partir de esta información, el algoritmo es capaz de estimar el criterio de similitud para considerar la incorporación de puntos a cada región y llevar a cabo de este modo la segmentación de la imagen. La estrategia aplicada resulta así en un esquema semiautomático, ya que posee una primera etapa interactiva de selección de puntos, seguida por un proceso automático de crecimiento. Además de esta posibilidad, también se permite que los parámetros que caracterizan el criterio de crecimiento puedan ser ajustados por el usuario en caso de considerarlo necesario.

La estrategia de agrupamiento utilizada permite considerar diferentes criterios para evaluar la similitud de los elementos y además facilita la incorporación de conocimiento adicional sobre las características de la imagen y de las estructuras particulares que se desean segmentar, de manera de orientar el proceso de crecimiento. Esto es particularmente importante cuando se trata de aplicar la estrategia desarrollada a la segmentación de componentes específicas, de acuerdo a cada aplicación particular. Además, el algoritmo contempla la aplicación de estrategias de resolución de conflictos para efectuar la asignación de puntos ubicados en la frontera entre diferentes componentes. Finalmente, a partir de las regiones segmentadas es posible generar un modelo de superficies con el fin de evaluar el resultado de la segmentación mediante el *rendering* de la imagen en un ambiente de visualización. El modelo además permite obtener la información necesaria de manera de extraer características de las regiones detectadas y poder usar esta información para el

cálculo de medidas y comparaciones, por ejemplo en el caso del cálculo de dosis en tratamientos de radioterapia [12].

### Pre-procesamiento de la imagen

Las imágenes obtenidas a partir de los diferentes dispositivos de captura consisten de una serie secuencial de cortes digitales transversales de la zona analizada, a partir de los cuales es posible generar una estructura tridimensional (3D) que simule la geometría del objeto original. Cada uno de los elementos de este volumen (o voxels) se considera de valor constante, asociado a algún atributo medible del objeto real, dependiendo de la modalidad de imagen considerada. Por ejemplo, en el caso de una CT representa el valor de atenuación de rayos X debido a los materiales presentes en el volumen, mientras que en una MRI se asocia a características de densidad y movilidad de protones.

A causa de las características físicas de los equipos de captura, la distancia entre los sucesivos cortes suele ser mayor que la distancia entre las muestras dentro de cada capa, produciendo una imagen 3D de resolución anisotrópica. Esta situación implica que se debe considerar el tratamiento de voxels de tamaño arbitrario durante el proceso de segmentación y aún durante la visualización. Sin embargo, las imágenes generadas de este modo presentan un efecto de *jagging* bastante notorio, especialmente cuando poseen una cantidad reducida de cortes (Figura 1.a). Otra opción de tratamiento de la imagen consiste en la generación de capas intermedias, calculadas por interpolación de la información provista por los cortes originales contiguos (Figura 1.b). De esta manera, es posible mantener la relación de aspecto del objeto original y además se logra reducir notoriamente el efecto mencionado anteriormente.




Figura 1: construcción del modelo 3D de una CT: (a) considerando voxels de tamaño irregular según la distancia entre capas, (b) voxels cúbicos por interpolación de capas

### Segmentación por crecimiento de regiones

El objetivo del algoritmo de crecimiento de regiones es determinar zonas uniformes dentro de la imagen, a partir de sus propiedades locales. En el esquema propuesto es posible efectuar la detección de una o más regiones de interés, de acuerdo a cada aplicación particular. El crecimiento se inicia a partir de la especificación de puntos iniciales para cada región y luego, mediante un proceso iterativo, se van incorporando a las mismas los voxels de la imagen que satisfacen un criterio de conectividad y similitud determinado, hasta que no se encuentren más elementos que cumplan la condición [9].

Numerosos algoritmos de segmentación se aplican a los cortes individuales de la imagen y luego integran los resultados parciales para conformar el volumen total segmentado. En este trabajo, la segmentación se aplica directamente sobre el modelo 3D, evitando de este modo los problemas de puesta en correspondencia entre cortes que poseen los esquemas mencionados. Este esquema resulta conveniente sobre todo en casos de componentes complejas, como por ejemplo en el caso de segmentación de estructuras como cráneo o cerebro, que al poseer numerosas circunvoluciones puede provocar que puntos que no han sido integrados a la región en alguno de los cortes, sí pueden resultar incluidos en los cortes contiguos.

### ***Definición de semillas***

La determinación del punto de partida para la segmentación de las regiones suele ser un aspecto crítico del algoritmo. Se han propuesto diferentes alternativas para esta etapa, las cuales se discuten extensamente en [4]. Algunos trabajos tratan de especificar semillas en forma automática, por ejemplo a partir de un análisis del histograma de la imagen o como resultado de una segmentación previa con otras técnicas [13]. Sin embargo, la complejidad y variabilidad de las estructuras anatómicas comúnmente presentes en las imágenes médicas tiende a limitar el alcance de la aplicabilidad de los métodos completamente automáticos. Además, la ubicación de los puntos iniciales sobre zonas ruidosas o correspondientes a bordes puede provocar una segmentación errónea de la imagen, la cual finalmente podría requerir una etapa posterior de corrección. Contrariamente, otros enfoques de segmentación se basan en una especificación de semillas por parte del usuario, a partir de su conocimiento experto [3,9].

En este trabajo se ha considerado este último enfoque, ofreciendo un entorno de visualización con una interface interactiva para la determinación de las semillas, con el fin de facilitar esta tarea a través de la exploración de la imagen 3D, sabiendo que tales puntos ciertamente pertenecen a cada una de las estructuras buscadas. Con el fin de asistir al usuario en este proceso, la herramienta brinda información sobre la posición, tonalidad y gradiente en cada punto (Figura 2). Debido a que la segmentación resultante del crecimiento desde una única semilla suele ser insuficiente en ciertos casos, se ha considerado la posibilidad de poder establecer más de una semilla como una opción del algoritmo. Esto es especialmente conveniente para la segmentación de regiones que no corresponden necesariamente a una única pieza, como por ejemplo el cráneo. Una vez especificada, cada semilla contiene la siguiente información:

- posición: dada por las coordenadas  $x$ ,  $y$ ,  $z$  dentro del punto dentro del volumen de datos (debido a la manera en que cada una es determinada se asume que pertenece a la región),
- intensidad: el valor de tonalidad de cada punto semilla se utiliza en la evaluación los voxels visitados por el proceso de crecimiento.

Cabe destacar que mediante las semillas se especifican los puntos de la imagen que brindan información sobre lo que el usuario considera relevante y, de esta manera, se incorpora al proceso de segmentación conocimiento relevante acerca de las características de interés. A partir de ella, el algoritmo de crecimiento es capaz de determinar el conjunto de componentes conectadas con propiedades similares que conforman cada región.

### *Algoritmo de crecimiento*

Inicialmente, cada región queda constituida por el conjunto de semillas que han sido especificadas. En cada paso, se analizan los voxels vecinos a los ya integrados con el fin de evaluar si satisfacen la condición de aceptación establecida. En este caso, son insertados en una cola de prioridad hasta el momento de ser procesados e incorporados a la región correspondiente. El ordenamiento se efectúa con respecto a un factor de calidad para cada

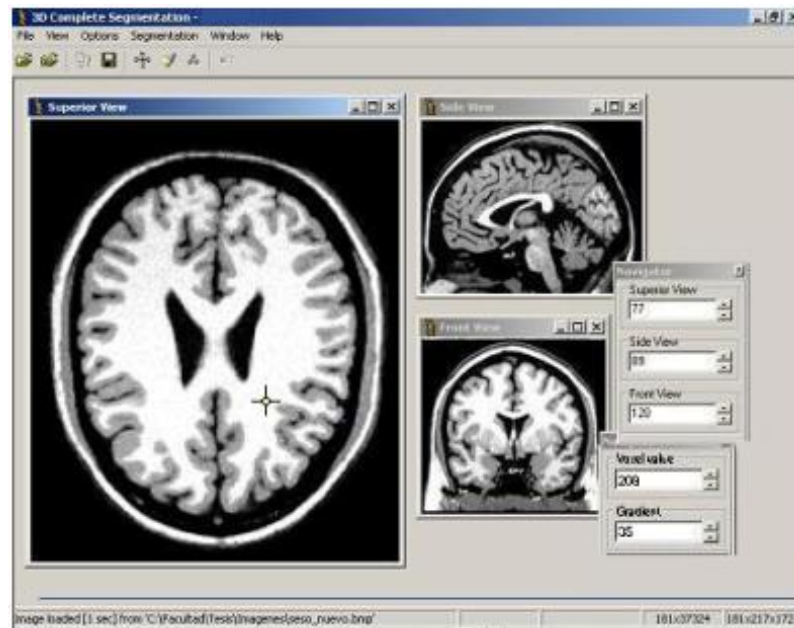


Figura 2. Vista de la herramienta. Selección de semillas

voxel, el cual es una medida de la diferencia que el punto posee con respecto a la región a la cual será integrado, como se describe en la sección siguiente.

En cada ciclo, se extrae el primer elemento de la lista para rotularlo como perteneciente a la región correspondiente y luego se analiza la posible extensión sobre los vecinos en caso de que satisfagan la condición del crecimiento. En la Figura 3 se muestran sucesivas etapas de crecimiento sobre un corte axial de una MRI (Caso 1 - Tabla 1). Los puntos que no cumplen con el criterio se marcan como descartados por esa región. Debido a que en cada paso se incorpora a la región correspondiente el voxel con mejor factor de calidad, las regiones más homogéneas crecerán más rápidamente que las otras. Esto reduce la oportunidad de conflictos posteriores, en caso de que alguna región logre acaparar puntos que en realidad correspondían a otra componente, como se explica más adelante.




Figura 3. Etapas del algoritmo de crecimiento de regiones (vista sobre un corte axial de una MRI)

El algoritmo admite la incorporación de condiciones de corte de crecimiento globales o propias a cada región. Las posibilidades en este punto son variadas, aunque en el caso de aplicaciones médicas suele ser una tarea dificultosa debido a la complejidad de las estructuras consideradas, por lo que se debe tener cuidado de especificar tales condiciones cuidadosamente, de acuerdo a cada caso particular. Esta alternativa puede ser utilizada por el usuario con el fin de realizar una especie de ajuste sucesivo del proceso de llenado. Así, por ejemplo, si se conoce el volumen aproximado de una componente determinada, el algoritmo fácilmente puede realizar una conversión de la medida especificada a la cantidad de voxels que aproximadamente deben ser incluidos a la región, de manera de no permitir la inclusión de más elementos que los especificados. Luego, en base al análisis del resultado, se puede requerir un afinamiento del valor de volumen y re-segmentar la imagen de considerarse necesario.

La salida del algoritmo consiste de una estructura de iguales dimensiones que la imagen original, en la cual aparecen rotuladas las distintas componentes correspondientes a las regiones detectadas (Figura 4). Esta información se tiene en cuenta además durante la etapa de visualización del volumen segmentado y en la generación de la geometría de las superficies detectadas.

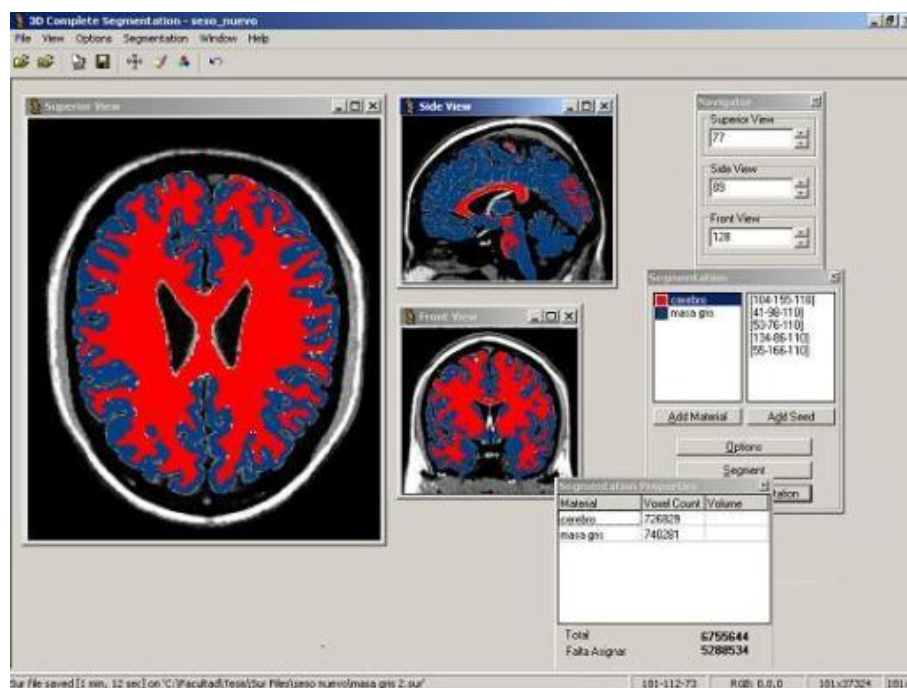


Figura 4. Vista de regiones segmentadas sobre un corte axial de una MRI

### ***Evaluación de pertenencia a la región***

Debido a la variabilidad de intensidades dentro de una misma componente y a la posible presencia de ruido en la imagen, el criterio de similitud utilizado para el crecimiento debe contemplar un cierto valor de tolerancia para las diferencias de tonalidades entre los voxels de cada región. Este valor puede ser provisto por el usuario; sin embargo, como se expresó anteriormente, el concepto de similitud no es fácilmente traducible a un valor numérico. Por esto, el algoritmo provee una estimación de la tolerancia para cada región utilizando la información provista por las semillas especificadas. Este valor resulta a partir del desvío standard de las tonalidades en una zona en torno a cada uno de sus puntos iniciales, el cual posteriormente puede ser ajustado si se considera conveniente.

Se han analizado diferentes variantes para realizar la evaluación de pertenencia a una región. El criterio más simple considera el contraste de intensidades entre el voxel analizado y el valor promedio de las semillas. Otra posibilidad es comparar la intensidad del voxel visitado en relación a la del voxel vecino recientemente incorporado a la región. También se puede evaluar el valor del gradiente 3D en el punto. Finalmente, un criterio más elaborado considera la variación de intensidades con respecto al voxel evaluado y también a su entorno, integrando la evaluación del gradiente en el punto. A continuación se describen los distintos criterios analizados:

- *Crecimiento según semilla.* Cada nuevo voxel visitado se incorpora a la región correspondiente si la diferencia entre el valor del voxel y el promedio de intensidades de las semillas especificadas para la región se encuentra dentro de cierto nivel de tolerancia. Debido a que sólo se controla la similitud de los voxels individuales, los puntos con ruido son excluidos de la región y por lo tanto puede requerirse posteriormente un post-procesamiento de la imagen segmentada con el fin de



completar la integración de tales puntos por similitud al entorno [14].

- *Crecimiento según vecino.* En este caso se considera que un voxel pertenece a una región si la diferencia entre su intensidad y la del vecino anteriormente incorporado a la misma se encuentra dentro de la tolerancia especificada. Cuando el proceso de crecimiento se aproxima a los bordes de la región, la diferencia de intensidades comienza a aumentar, por lo tanto este criterio ocasionará que el algoritmo se detenga en esa zona. Debido a que las intensidades van variando progresivamente, el factor de tolerancia elegido es determinante para controlar la posibilidad de desborde del llenado sobre otros componentes contiguos.
- *Crecimiento por gradiente.* La magnitud del gradiente en un punto es una medida de la variación de intensidades alrededor de él [5]. Esta alternativa de crecimiento utiliza este valor para establecer los límites de la región, ya que el proceso de llenado se detiene si el gradiente en un voxel supera el umbral dado y el voxel en cuestión se excluye de la región. La idea es similar al caso anterior, sin embargo es un criterio más robusto ya que en el cálculo del gradiente se tienen en cuenta las diferencias finitas con los vecinos alrededor del voxel en los tres ejes cartesianos. El problema radica en que, como ya se mencionó anteriormente, un criterio de evaluación basado sólo en el gradiente posee problemas similares a los de los algoritmos derivativos detectores de bordes.
- *Crecimiento por entorno.* Esta estrategia se basa en considerar no sólo la diferencia entre el voxel y las semillas, sino también la correspondiente al entorno del voxel, considerado como un cubo alrededor del punto analizado, cuya dimensión puede ser variable. De esta manera, no sólo se compara el voxel individual, sino los puntos vecinos, impidiendo de esta manera que se produzcan dos situaciones que no son controlables en los casos anteriores: por un lado, impide la exclusión de puntos ruidosos, ya que si el entorno es similar a los puntos semilla, se considera que el punto central posee ruido e igualmente se lo incluye a la región; por otro lado, previene la posibilidad de desbordes del crecimiento hacia otras componentes de la imagen por conductos delgados, ya que se exige que el entorno también sea similar para poder incluir el punto central a la región.
- *Criterio integrado.* En este caso la información acerca de los bordes proveniente del mapa de gradientes de la imagen se incluye en la condición de aceptación junto con la evaluación del contraste entre las intensidades del entorno del voxel analizado y el promedio de las intensidades de las semillas, para controlar el crecimiento de la región. La integración de ambos criterios asegura la detención del llenado sobre zonas de transición entre componentes, controlando el problema de sobre-segmentación. Con el fin de relajar la exigencia de similitud de todo el entorno, la cual torna al criterio demasiado estricto y puede generar huecos dentro de la región segmentada, se ha considerado la similitud de un porcentaje de voxels dentro del entorno. Esta estrategia brinda mayor flexibilidad que el caso anterior, a la vez limita las oportunidades de escape.

En general, los dos primeros criterios analizan sólo la información individual del voxel, permitiendo una rápida evaluación de pertenencia, pero su simplicidad también puede provocar situaciones no deseables por lo que deben utilizarse en forma controlada. Todas las opciones obligan de alguna manera a que el algoritmo de crecimiento se detenga en

zonas próximas a los bordes de la región; sin embargo, el crecimiento por gradiente en el punto o por evaluación del entorno ofrece un criterio más robusto, disminuyendo la posibilidad de desbordes hacia otras componentes, por lo que resultan opciones más convenientes (Figura 5).




Figura 5. Resultado de la segmentación de cerebro en una MRI: (a) se producen desbordes de la región, (b) la segmentación mediante evaluación del entorno evita la sobre-segmentación

Finalmente, la opción que ha brindado los mejores resultados consiste en la integración del criterio de evaluación del entorno y la información sobre el valor del gradiente en el punto analizado. Enfoques similares a este se han utilizado también en otros trabajos (ver [15], por ejemplo), aunque en nuestro caso la evaluación del contraste se efectúa con respecto a la media de intensidades de los puntos semilla, sin requerir re-actualizaciones ante cada operación de inserción. En cuanto a la dimensión especificada para el cubo, cabe notar que ésta influye directamente en el comportamiento del algoritmo de crecimiento, principalmente en zonas cercanas a los bordes. En general, un cubo de tres voxels de lado resulta adecuado para la detención del crecimiento en la frontera de las componentes y la prevención de desbordes, sin aumentar considerablemente el costo computacional. Cuando la propagación del llenado se configura con radios mayores, el espacio hacia donde el frente de avance se puede propagar es más restrictivo. Esto puede mejorar notablemente el resultado del algoritmo, ya que en imágenes médicas frecuentemente las transiciones entre componentes son difusas. La desventaja de usar radios amplios es que el algoritmo de segmentación se hace más lento y además la frontera de las regiones resultantes puede distar considerablemente de los bordes reales de la imagen. Sin embargo, en este caso es posible aplicar un algoritmo de extensión de la frontera limitado por niveles, como se describe más adelante.

### ***Extensión de la frontera***

Una vez segmentadas las componentes de interés, es posible realizar una extensión adicional de las componentes detectadas mediante el algoritmo de crecimiento de regiones. Para ello, se aplica una etapa de crecimiento a partir de las fronteras actuales mediante un

algoritmo de búsqueda en amplitud (BFS= Breadth First Search) y de manera restringida a cierta cantidad de niveles. Esta opción es especialmente apropiada cuando se ha aplicado la estrategia integrada de crecimiento de regiones o el crecimiento por evaluación del entorno ya que, dependiendo de la dimensión del cubo, puede suceder que el llenado no alcance plenamente los límites reales del material analizado.

La aplicación de una etapa de crecimiento adicional a partir de cada elemento en el límite de la región permite que la región alcance con mayor precisión los límites reales de la estructura. En este caso se debe considerar un entorno de menor dimensión que el utilizado durante el llenado inicial y además con una cantidad fija de niveles de profundidad para no provocar desbordes, ya que el llenado no puede extenderse más allá de la distancia especificada. Una estrategia conveniente es crecer una cantidad de niveles dada por la dimensión del entorno sobre 2, ya que se supone que la frontera de la región pudo crecer inicialmente hasta esa distancia del borde real.

### ***Tratamiento de conflictos***

En el proceso de segmentación, cada una de las componentes intenta crecer en todas direcciones a partir de su borde actual. Cuando dos o más frentes de avance se encuentran, puede surgir algún tipo de conflicto que debe ser resuelto de algún modo.

Básicamente, se pueden presentar dos situaciones diferentes cuando una componente intenta crecer sobre un voxel ya asignado a una región. Una posibilidad es que el voxel en realidad se encuentre integrado a la misma componente, y por lo tanto en este caso simplemente no hay conflicto y los frentes de avance se fusionan en una misma región. Esto puede suceder en el caso de haber especificado más de una semilla para una misma estructura anatómica, como puede ser para el caso del cráneo, como se mencionó anteriormente. Una ventaja del método de crecimiento de regiones sobre otras alternativas de detección de superficies, como *marching cubes* por ejemplo, es que este tratamiento se realiza sobre los valores discretos de la imagen, no sobre mallas de superficie, por lo que no hay necesidad de resolver intersecciones [16].

Otra situación diferente puede presentarse cuando una región en su proceso de crecimiento visita un voxel que cumple su criterio de evaluación, pero actualmente se encuentra asignado a otra componente. En la Figura 6 se muestra un ejemplo de esta situación, para una región R2 que avanza sobre otra región R1. En este caso se supone que el punto de color gris oscuro puede ser incluido en R1, pero el frente en avance de R2 lo visita también. En este caso se podría desestimar el conflicto, dejando el voxel en la región R1 y proseguir el crecimiento de R2 sobre los restantes puntos. Sin embargo, si se evalúa la diferencia con respecto a la intensidad de las semillas, puede suceder que en realidad ese punto sea más similar a R2, aunque se encuentre previamente asignado a R1. Por lo tanto, una solución conveniente ante esta situación sería reasignar el punto a R2, permitiendo que el crecimiento continúe a partir de dicho punto de manera similar. La estrategia de resolución de conflictos es la encargada de tomar el control en este punto y definir cuál es el material más indicado para apropiarse del voxel.

Una alternativa para resolver el conflicto consiste en evaluar la diferencia entre la intensidad del voxel en conflicto con respecto a la intensidad media de cada una de las regiones que lo reclaman. Este valor medio se va calculando mientras se realiza la segmentación, actualizándolo cada vez que un voxel es aceptado como perteneciente a una

componente. La región seleccionada será aquella cuya diferencia absoluta entre el valor del voxel y la media de la región sea más pequeña. De este modo, el esquema de resolución de conflictos permite que finalmente cada región incluya los voxels que son más similares a sus semillas, aunque en este caso algunos puntos serán evaluados más de una vez, aumentando levemente la complejidad del algoritmo.

Otra estrategia consiste en la evaluación de la similitud del entorno del voxel con respecto a la media de las diferentes regiones, con el fin de evitar el efecto negativo de la presencia de voxels ruidosos, de intensidad distante de su entorno.




Figura 6. Situación de conflicto entre dos regiones diferentes

### Descripción de las superficies de las regiones

Comúnmente, los objetos tridimensionales se describen a través de modelos de superficie con el fin de poder ser visualizados mediante primitivas gráficas. Las técnicas habitualmente usadas para extraer iso-superficies se conocen como *Marching Cubes* [16] y *Marching Tetrahedra* [17]. Ambas son veloces y eficientes, pero suelen presentar problemas en cuanto a la calidad y cantidad de los polígonos generados y además sufren de los inconvenientes propios de los métodos basados en umbrales.

Se ha desarrollado para esta etapa un algoritmo de generación de superficies para ser aplicado a partir del resultado de la segmentación previa. Esta técnica se basa en encontrar los límites entre las componentes resultantes del crecimiento de regiones y consta de dos etapas. En un primer paso, se recorre el volumen segmentado en búsqueda de voxels adyacentes correspondientes a interior y exterior de una región, o a dos regiones diferentes, considerando las caras de los voxels que corresponden al contorno de la región de interés. A partir de estas caras frontera se puede generar una triangulación inicial, dividiendo cada una de ellas en dos triángulos, a partir del trazado de una diagonal. Cada esquina de un voxel frontera constituye un vértice de una malla regular en la imagen y entonces cada triángulo se puede describir por la tripla de vértices que lo determinan.

El conjunto de triángulos obtenido describe las superficies de cada región segmentada, aunque la imagen resultante ofrece un aspecto escalonado que entorpece la visualización. Esto se debe a que los triángulos se generan a partir de las caras de los voxels (Figura 7.a). por este motivo, se aplica una etapa de suavizado de la superficie para disminuir las irregularidades y lograr una apariencia más semejante a las formas originales de los materiales (Figura 7.b). El suavizado se basa en el reemplazo de cada vértice por el promedio entre las posiciones de los demás vértices de los triángulos involucrados. El

proceso se puede aplicar en forma iterativa, hasta obtener una malla suave, producto de lograr una distribución más homogénea de los vértices.




Figura 7. Descripción poligonal de superficies: (a) triangulación inicial – (b) superficie suavizada

Durante el proceso de construcción de la malla de superficie, puede surgir algunas disposiciones de voxels que luego provocan situaciones conflictivas al aplicar el suavizado. Estas situaciones han sido estudiadas y se detectaron algunos casos problemáticos que ocurren cuando los voxels resultan unidos sólo por una arista o por un vértice en común. La solución adoptada incluye la detección de tales aristas y vértices conflictivos durante el proceso de generación de la superficie, tratando de determinar si se produce alguno de los casos de conflicto posibles. Si esto ocurre, los vértices involucrados son re-enumerados de manera que el algoritmo de suavizado los trate como puntos diferentes y los triángulos puedan ser despegados [14].

## Resultados

La estrategia de crecimiento de regiones permite obtener segmentaciones de resultados altamente satisfactorios. En la Tabla 1 se especifican algunas imágenes consideradas en los casos de estudio y en las Figuras 8 y 9 se presentan algunos resultados correspondientes a la visualización por *rendering* de superficies [18], obtenidas a partir del método descrito anteriormente. En todos los casos, la estrategia de evaluación de pertenencia a la región de interés consistió en la aplicación del criterio integrado de similitud del entorno (usando entornos de dimensión 3 y un 70% de puntos coincidentes dentro del mismo). La segmentación inicial se completó con una extensión de la frontera limitada a dos niveles. Como puede apreciarse, el llenado de la región ha logrado alcanzar las fronteras del material sin generar desbordes.

Tabla 1 – Casos de prueba

Caso	Tipo de imagen	Dimensiones	Material detectado
1	MRI	256x256x85	Cerebro

2	MRI	256x256x124	cerebro - tumor
3	CT	128x128x69	cráneo
4	CT	256x256x125	cráneo – piel

Como se especifica en la Tabla 1, los dos primeros casos corresponden a segmentaciones del cerebro en imágenes de resonancia magnética. En el segundo caso (Figura 8.b) se puede apreciar la presencia de un tumor en la parte superior, el cual ha sido segmentado como una componente diferente a partir de la especificación de una semilla en esa zona. En este caso se ha segmentado también la componente correspondiente a la piel, la cual aparece como levemente transparente para dejar ver las otras estructuras en el interior. Los ejemplos de la Figura 9 corresponden a imágenes tomográficas. La primera imagen muestra la segmentación del cráneo en forma aislada, mientras que la segunda exhibe tanto el cráneo como la piel, nuevamente con cierto grado de transparencia.




Figura 8. Visualización de segmentaciones de MRI de cabeza: (a) cerebro, (b) tumor en masa cerebral, dentro de la componente transparente correspondiente a piel




Figura 9. Visualización de segmentaciones de CT de cabeza: (a) cráneo, (b) cráneo y piel (con transparencia)

## Discusión

Se ha presentado una estrategia de segmentación aplicada a imágenes tridimensionales, en este caso provenientes de diferentes modalidades habitualmente empleadas en la práctica médica. El método, basado en el crecimiento de regiones asociadas a las diferentes estructuras anatómicas de interés, resulta simple y eficiente. La segmentación se complementa con un procedimiento de generación del modelo de superficies asociado a las regiones detectadas por el esquema de segmentación previo, incluyendo un enfoque novedoso para el tratamiento de situaciones conflictivas y un post-procesamiento de suavizado sobre la malla de polígonos obtenida. Los resultados obtenidos a partir de la aplicación del método sobre imágenes provenientes de tomografías y MRI son altamente satisfactorios y las superficies generalmente resultan de calidad superior a las generadas con otros métodos.

El algoritmo de llenado utilizado permite el empleo de diferentes variantes de evaluación de similitud, siendo más robusta la que contempla la integración de la información sobre bordes y el análisis del contraste de intensidades entre el entorno del voxel analizado y la región considerada. El algoritmo de crecimiento permite incorporar información sobre las propiedades de cada región particular, así como conocimiento previo general sobre las características de la imagen. Sin embargo, estos datos deben ser cuidadosamente incorporados, dependiendo de cada aplicación particular. Por otra parte, el análisis de otros criterios de incorporación de puntos y de resolución de conflictos diferentes a los presentados son temas que continúan en análisis. También se encuentra en investigación otros esquemas de integración del esquema de segmentación por crecimiento de regiones y estrategias de evolución mediante algoritmos de optimización de contornos.

## Referencias

- [1] Duncan J., Ayache N., *Medical Image Analysis: Progress over Two Decades and Challenges Ahead*, 2000, IEEE Transactions on Pattern Recognition and Machine Intelligence, Vol.22, No.1
- [2] Pham D., Xu C., Prince J., *A survey of current methods in medical image segmentation*, Annual Review of Biomedical Engineering, Vol.2, 2000
- [3] S.A.Hojjatoleslami, F.Kruggel, *Segmentation of large brain lesions*, IEEE Transactions of Medical Imaging, Vol.20, No.7, July 2001.
- [4] Olabarriaga S., Smeulders A., *Interaction in the segmentation of medical images: A survey*, 2001, Medical Image Analysis, Vol.5, 127-142.
- [5] Castleman K., *Digital Image Processing*, 1996, Prentice Hall.
- [6] Lakare S., Kaufman A., *3D Segmentation techniques for medical volumes*, Center for Visual Computing, Department of Computer Science, State University of New York, Research Proficiency Exam, Dec. 2000
- [7] Gonzalez R., Woods R., *Digital Image Processing*, Addison-Wesley, 1992
- [8] F.J.Canny, *A computational approach to edge detection*, IEEE Transactions on Pattern Analysis and Machine Intelligence, 8(6):679-698, 1986.
- [9] Adams R., Bischof L., *Seeded Region Growing*, IEEE Trans. Pattern Analysis and Machine Intelligence, Vol.16, No.6, June 1994

- [10] J.Freixenet, X.Muñoz, D.Raba, J.Martí and X.Cufí, *Yet another survey on image segmentation: region and boundary information integration*, A.Haeyden et al. (Eds.) ECCV 2002, LNCS 2352, pp.408-422, 2002.
- [11] Pohle R., Toennies K., *Segmentation of medical images using adaptive region growing*, Proc. SPIE (Medical Imaging 2001).
- [12] D.Fernandez, B.Penesi, F.Ribeiro, M.del Fresno, M.Vénere, *Planificación automatizada de tratamientos de radioterapia*, Proceedings CACIC '2000, Ushuaia, Argentina, 2000.
- [13] Fan J., Yau D., Elmagarmid A., Aref W., Automatic image segmentation by integrating color-edge extraction and seeded region growing, 2001, IEEE Trans. on Image Processing, Vol.10, No.10
- [14] Un método de segmentación de imágenes digitales tridimensionales por crecimiento de regiones, M. del Fresno, M. Vénere, VIII Congreso Argentino de Ciencias de la Computación CACIC 2002, Buenos Aires, 15-18 octubre de 2002.
- [15] Y. Xiaohan, J.Yla-Jaaski, O.Huttunen, T.Vehkomaki, O.Sipild, and T.Katila. Image segmentation combining region growing and edge detection. IAPR International Conference on Pattern Recognition, vol.C: 481-484, Netherlands, 1992.
- [16] Lorensen W., Cline H., Marching Cubes a high resolution 3D surface reconstruction algorithm, 1987, Computer Graphics, Vol 21, No.4, pp 163-169
- [17] Carneiro B., Silva C., Kaufman A., Tetra-Cubes: An algorithm to generate 3D isosurfaces based upon tetrahedra, 1996, IX SIBGRAPI, 205-210
- [18] Watt A., *3D Computer Graphics*, Addison-Wesley, 2nd. ed., 1993

**Datos de Contacto:**

*Mariana del Fresno. Pladema-ISISAN. Universidad Nacional del Centro. Pinto 399, (7000) Tandil, Prov. Buenos Aires. E-mail: mdelfres@exa.unicen.edu.ar*